

ENEL445 Roy Smith Optimisation Block

Learning Guide: Least Squares, Convex Optimisation, LMIs, and MPC

Contents

1	Source Materials	2
2	Study Strategy	2
3	Mindmap-based Learning Path	6
4	Least Squares: Core Formulation	7
5	Nonlinear Least Squares and Gauss/Ceres	29
6	Statistical Properties of Least Squares	34
7	Regularisation and Validation	54
8	Convex Sets and Convex Optimisation	58
9	Problem Classes: LP, QP, SOCP, QCQP, SDP	59
10	LMI and Schur Complement	61
11	Model Predictive Control	62
12	Tutorial and Exercise Route	64
13	Exam Templates and Common Mistakes	77
14	Appendix: Practical EDA for Candidate Φ	81
15	Appendix: Φ as Hidden Structure and Dynamics	89
16	Appendix: Math Background - SVD and Pseudo-inverse	95
17	Appendix: Projection Geometry and Instrumental Variables	100

18 Self Check	106
19 Minimum Memory List	107

1 Source Materials

本学习指导基于本章 Roy Smith 相关课件、练习和 6 节转录内容整理。主线不是逐字复述 lecture，而是按考试复习逻辑重构：

- Least-Squares Problems and Methods/Lecture 6 Least squares regression part 1.pdf
- Least-Squares Problems and Methods/Lecture 7 Least squares regression part 2.pdf
- Convex Optimisation, LMIs, and MPC/Lecture-8-Convex-optimisation-part-1.pdf
- Convex Optimisation, LMIs, and MPC/Lecture-9-Convex-optimisation-part-2.pdf
- Convex Optimisation, LMIs, and MPC/ Lecture-10- Convex- optimisation- part-3- model- predictive-control-(MPC).pdf
- exercises/LS_exercises.pdf
- exercises/Statistics_exercises.pdf
- exercises/Convex_Opt_exercises.pdf
- transcribe/20260504_Lecture_6_least_squares_regression_part_1.md
- transcribe/20260505_Lecture_7_least_squares_statistics_BLUE.md
- transcribe/20260506_Least_squares_regularisation_validation.md
- transcribe/20260511_Lecture_8_convex_sets_cones_ellipsoid_method.md
- transcribe/20260512_Lecture_9_LMI_SDP_control_design.md
- transcribe/20260513_Lecture_10_model_predictive_control_MPC.md

补充理解 Φ 的 cross-course reading：

- DATA423/Lectures/FeatureEngineering-2024.pdf
- DATA423/Lectures/FeatureExtraction-2024.pdf
- DATA423/Lectures/FeatureSelection-2024.pdf
- DATA423/Lectures/10_Model Selection-2025.pdf

2 Study Strategy

这组材料是混合型章节：前半部分是 least squares 的计算与统计解释，后半部分是 convex optimisation、LMI 和 MPC 的建模框架。复习时不要按日期机械背，而要按下面的问题链组织：

真实工程问题

-> 数据/系统模型

-> 变量、约束、目标函数

-> 是否是 least-squares 或 convex problem

-> 可用公式、solver 或 iterative method
 -> 考试题型和易错点

最重要的三类能力：

1. 会把问题写成 optimisation form。
2. 会解释公式背后的统计或几何意义。
3. 会判断一个问题属于 LS、LP、QP、SOCP、SDP/LMI 或 MPC 中哪一类。

2.1 Roy's Warning: From Model-Based to Data-Driven Optimisation

Roy 在 Anscombe dataset 之后强调了一个更大的变化：optimisation problem 在最近几十年里越来越多地从 model-based workflow 走向 data-driven workflow。

传统工程 optimisation 更常见的是：

```
known process / engineering model
-> decision variables
-> constraints
-> objective function
-> solver
```

例如 refinery scheduling、production planning、power dispatch、transport logistics、control design。这些问题的重点通常是：系统模型、约束和目标大致已知，工程师需要把它们写成 optimisation formulation。

现在越来越多问题变成：

```
raw data
-> fit statistical / ML model
-> use fitted model inside optimisation
-> make decisions
```

例如：

- demand forecasting → inventory optimisation;
- load forecasting → power dispatch;
- price prediction → bidding strategy;
- traffic prediction → routing;
- learned surrogate model → design optimisation;
- customer model → recommendation or pricing optimisation。

这带来一个额外风险：如果前面的 fitted model 错了，后面的 solver 仍然会非常认真地优化一个错误的 objective、constraint 或 parameter estimate。

所以 Anscombe dataset 的意义不只是“画图好看”。它提醒我们：

data-driven optimisation requires data diagnostics before optimisation.

旧式 model-based optimisation 的主要风险是：

```
wrong formulation
missing constraints
bad scaling
solver or numerical issues
```

data-driven optimisation 额外增加了：

```
wrong fitted model
biased training data
insufficient features
outlier-driven fit
poor extrapolation
unvalidated learned objective or constraint
```

Roy 进一步指出，现代 data-driven optimisation 的数据经常来自 population，很多时候 literally 是人的 population：customers、drivers、patients、students、users、households、market participants。这样的数据天然带有 noise 和 stochastic variation。

原因不是单一的 measurement error，而是多种不确定性叠加：

- 不同个体有不同偏好和行为习惯；
- 同一个人在不同时间也可能行为不同；
- 有很多未观测变量；
- survey、sensor、transaction logs 会有记录误差；
- sample 只是 population 的一部分；
- 行为模式会随时间、政策、价格、天气、社会事件改变；
- model 总会遗漏某些解释因素。

所以 population data 更像：

$$y = \text{systematic signal} + \text{random variation}$$

在 least-squares 形式里就是：

$$y = \Phi\theta + \epsilon$$

这里的 ϵ 不只是仪器测量误差，也包括 unmodelled behaviour、sampling variation、omitted variables 和 genuinely random shocks。

因此现代 optimisation 常常变成：

```
noisy / stochastic data
-> estimate model and uncertainty
-> validate model
-> optimise under uncertainty
```

这就是为什么 Roy 说我们需要能处理 noisy data 或 stochastic data 的 optimisation methods。它们不是在假装数据干净，而是在承认：

optimisation decisions may depend on quantities estimated from noisy data.

对应到本章工具：

Tool	What uncertainty issue it addresses
residual analysis	checks whether unexplained variation looks structured or random
weighted LS	handles unequal noise variance
BLUE	handles covariance structure and minimum-variance unbiased estimation
validation	tests whether fitted structure predicts unseen data
regularisation	reduces variance and instability when fitting noisy data
stochastic / robust optimisation	later-stage tools when uncertainty enters decisions directly

因此本章 least-squares 的 Φ 、rank、residual、validation、regularisation 不只是统计工具。它们是在回答：

Can I trust the data-derived model that I am about to optimise over?

复习优先级：

Priority	Topics
Must know	LS formulation, normal equations, BLUE, bias/variance/MSE, regularised LS, convexity definition, LP/QP/SOCP/SDP/LMI classification, MPC formulation
Should know	nonlinear LS linearisation, ellipsoid method idea, Schur complement, stability/state-feedback LMI ideas, explicit MPC
Recognise only	S-procedure details in convex exercise problem 3, deep implementation details of CVX/YALMIP

3 Mindmap-based Learning Path

学习顺序建议如下：

1. **Least squares as optimisation:** 先理解 $y = \Phi\theta + \epsilon$ 、residual、normal equations。
2. **Least squares as statistics:** 再理解 $\hat{\theta}$ 是随机变量，所以要看 bias、variance、MSE。
3. **Regularisation:** 之后看为什么最小 training residual 不等于最好 prediction。
4. **Convex foundations:** 学 convex set、cone、PSD cone、ellipsoid。
5. **Problem classes:** 把 LP、QP、SOCP、QCQP、SDP/LMI 放在同一张分类图里。
6. **LMI tools:** 用 Schur complement 和 PSD cone 理解 matrix constraints。
7. **MPC:** 把前面 optimisation framework 用到 control: finite horizon、constraints、replanning。

3.1 Tomorrow's Reading Route for Lectures 6–7

如果明天直接用这份 guide 复习 least squares，不建议从头到尾等权阅读。建议按下面路线走：

Pass 1: Core mechanics

```
model y = Phi theta + epsilon
-> build Phi
-> normal equations
-> geometric projection
-> basis functions and nonlinear LS
```

Pass 2: Statistical meaning

```
theta_hat is random
-> unbiasedness
-> variance / MSE / consistency
-> BLUE and inverse-variance weighting
-> correlated-noise BLUE
```

Pass 3: Prediction and practice

```
bias-variance tradeoff
-> regularisation
-> validation
-> do the Lecture 6--7 practice set
```

For exam preparation, the high-frequency least-squares items are:

Priority	You should be able to do
Very high	build Φ , derive normal equations, explain projection/residual orthogonality
Very high	prove OLS unbiased under $E[\epsilon] = 0$ and fixed Φ

Priority	You should be able to do
Very high	derive inverse-variance weights and explain BLUE
High	handle correlated noise using $(\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} y$
High	explain $\text{MSE} = \text{bias}^2 + \text{variance}$ and why regularisation can reduce MSE
Medium	explain nonlinear LS / Gauss-Newton as repeated linearised LS
Medium	discuss rank, condition number, pseudo-inverse, and why normal equations may be numerically poor

4 Least Squares: Core Formulation

4.1 What Problem Does LS Solve?

Least squares 解决的是：模型无法完全通过所有数据点时，如何选择参数使 residual 最小。

线性模型写成：

$$y = \Phi\theta + \epsilon$$

其中：

- $y \in \mathbb{R}^N$ 是观测输出；
- $\Phi \in \mathbb{R}^{N \times d}$ 是 regressor/design matrix；
- $\theta \in \mathbb{R}^d$ 是待估参数；
- ϵ 是误差或 residual。

这里默认的是 ordinary LS assumption：误差被建模为加在 y 上，而 Φ 被当作 known / fixed。如果 Φ 也有 measurement error，例如

$$y = (\Phi + \Delta\Phi)\theta + \epsilon,$$

那就进入 errors-in-variables / total least-squares 的问题，不再是普通 OLS 的标准设定。

标准 LS 问题：

$$\min_{\theta} \|y - \Phi\theta\|_2^2$$

等价 constrained form：

$$\begin{aligned} \min_{\theta, \epsilon} \quad & \|\epsilon\|_2^2 \\ \text{subject to} \quad & y - \Phi\theta = \epsilon \end{aligned}$$

考试中常见任务：

- 给出数据和模型，写出 Φ 、 y 、 θ ；
- 写出 LS optimisation problem；
- 推出 normal equations；
- 判断能不能使用 closed-form inverse。

4.2 Understanding Φ : Regressor Structure, Rank, and Real Data

Φ 是 least-squares 里最重要的对象之一。它不是凭空捏造的矩阵，而是把“我们认为哪些变量能解释 y ”这件事写成矩阵形式。

可以先记住一句话：

Φ 的每一行对应一个 observation，每一列对应一个 regressor / feature / basis function。

如果有 N 个观测、 d 个待估参数，那么：

$$\Phi \in \mathbb{R}^{N \times d}$$

一般写成：

$$\Phi = \begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_N^T \end{bmatrix}$$

其中第 j 行

$$\phi_j^T = [\phi_{j1} \quad \phi_{j2} \quad \cdots \quad \phi_{jd}]$$

表示第 j 个 observation 下所有 regressors 的取值。预测值是：

$$\hat{y}_j = \phi_j^T \theta$$

把所有 observation 叠起来，就是：

$$\hat{y} = \Phi\theta$$

4.2.1 1. How Φ Represents the Regressor Structure

假设我们想拟合：

$$y \approx \theta_1 + \theta_2 x$$

对数据点 $x_1, \dots, x_N$, regressor matrix 是：

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_N \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}$$

如果改成二次多项式：

$$y \approx \theta_1 + \theta_2 x + \theta_3 x^2$$

则：

$$\Phi = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_N & x_N^2 \end{bmatrix}$$

如果用一般 basis functions：

$$f(x) = \sum_{i=1}^d h_i(x) \theta_i$$

那么：

$$\Phi_{ji} = h_i(x_j)$$

也就是说， Φ 的第 i 列就是第 i 个 basis function 在所有数据点上的取值。

因此，选择 Φ 本质上就是选择 model structure：

Model choice	Columns of Φ
constant + line	1, x
polynomial	1, x , x^2 , ...
Chebyshev basis	$T_0(x)$, $T_1(x)$, $T_2(x)$, ...

Model choice	Columns of Φ
conic fitting	$x^2, xy, y^2, x, y, 1$
physical linear model	measured inputs, sensitivities, known coefficients

4.2.2 2. Rank, Lose Rank, and Linear Dependence

Rank tells us how many independent columns Φ really has.

如果：

$$\text{rank}(\Phi) = d$$

则 Φ 有 full column rank，所有 columns 都提供了独立信息。此时：

$$\Phi^T \Phi$$

通常可逆，closed-form LS solution 才能写成：

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y$$

如果 Φ lose rank，意思是某些 columns 可以由其他 columns 线性组合出来。例如：

$$\phi_3 = 2\phi_2$$

那么第 3 列没有提供新的方向。模型里虽然写了两个参数 θ_2, θ_3 ，但数据无法区分它们的贡献，因为：

$$\theta_2 \phi_2 + \theta_3 \phi_3 = \theta_2 \phi_2 + 2\theta_3 \phi_2 = (\theta_2 + 2\theta_3) \phi_2$$

这会导致参数不唯一：很多组 θ_2, θ_3 可以给出同样的 prediction。

常见导致 lose rank 的原因：

- 两个 regressors 完全重复；
- 一个 column 是另一个 column 的倍数；
- intercept 和 dummy variables 同时设置不当；
- 数据点太少， $N < d$ ；
- 某个变量在数据中没有变化，例如所有 x_j 都一样；
- 工程系统里某些输入总是一起变化，导致无法分辨单独贡献。

4.2.3 3. Condition Number: Not Singular, But Almost Singular

Rank 讨论的是“是否精确线性相关”。Condition number 讨论的是“是否接近线性相关”。

对 Φ , condition number 可以直观理解为:

$$\kappa(\Phi) = \frac{\text{largest stretching direction}}{\text{smallest stretching direction}}$$

用 singular values 写就是:

$$\kappa(\Phi) = \frac{\sigma_{\max}(\Phi)}{\sigma_{\min}(\Phi)}$$

如果 $\sigma_{\min}(\Phi)$ 很小, 说明有些 column direction 几乎可以由其他 columns 解释。矩阵还没有完全 lose rank, 但已经非常接近。

直观解释:

- $\kappa(\Phi)$ 小: 不同 regressors 提供的方向比较独立, 估计较稳定;
- $\kappa(\Phi)$ 大: 某些 regressors 几乎重复, 参数估计会对 noise 很敏感;
- $\sigma_{\min}(\Phi) = 0$: 真的 lose rank, 某些参数方向不可辨识。

Normal equation 会形成:

$$\Phi^T \Phi$$

这会进一步放大 conditioning 问题:

$$\kappa(\Phi^T \Phi) = \kappa(\Phi)^2$$

这就是为什么 lecture 里强调: closed-form 解适合理论, 但实践中直接 invert $\Phi^T \Phi$ 可能数值不稳。

4.2.4 4. Is Φ Symmetric?

通常 Φ 本身不是 symmetric。

首先, Φ 往往不是 square matrix:

$$\Phi \in \mathbb{R}^{N \times d}$$

通常 N 是数据点数量, d 是参数数量, 两者不一定相等。所以大多数情况下, 问 Φ 是否 symmetric 没有意义。

真正 symmetric 的对象是：

$$\Phi^T \Phi$$

因为：

$$(\Phi^T \Phi)^T = \Phi^T (\Phi^T)^T = \Phi^T \Phi$$

所以 $\Phi^T \Phi$ 一定是 symmetric。

而且它还是 positive semidefinite：

$$z^T \Phi^T \Phi z = (\Phi z)^T (\Phi z) = \|\Phi z\|_2^2 \geq 0$$

如果 Φ full column rank，那么对所有 $z \neq 0$ ：

$$\Phi z \neq 0$$

因此：

$$z^T \Phi^T \Phi z > 0$$

这时 $\Phi^T \Phi$ 是 positive definite，也就可逆。

所以关键关系是：

$$\Phi \text{ full column rank} \iff \Phi^T \Phi \text{ positive definite} \implies (\Phi^T \Phi)^{-1} \text{ exists}$$

4.2.5 5. Where Does Φ Come From in Real Problems?

Φ 来自 model design，不是从空气里随便写出来。常见来源有四类。

第一类：来自你选择的 mathematical basis。

例如 polynomial fitting 里，选择：

$$1, x, x^2$$

就决定了 Φ 的列是：

$$\begin{bmatrix} 1 \end{bmatrix}, \quad \begin{bmatrix} x_1 \\ x_2 \\ \vdots \end{bmatrix}, \quad \begin{bmatrix} x_1^2 \\ x_2^2 \\ \vdots \end{bmatrix}$$

第二类：来自 physical model。

例如一个线性化工程模型可能写成：

$$y \approx au_1 + bu_2 + c$$

其中 u_1, u_2 是测到的输入。那么：

$$\Phi = \begin{bmatrix} u_{1,1} & u_{2,1} & 1 \\ u_{1,2} & u_{2,2} & 1 \\ \vdots & \vdots & \vdots \\ u_{1,N} & u_{2,N} & 1 \end{bmatrix}, \quad \theta = \begin{bmatrix} a \\ b \\ c \end{bmatrix}$$

第三类：来自 linearisation。

如果原模型是 nonlinear：

$$y = H(\theta)$$

在 nominal point θ_i 附近线性化：

$$H(\theta) \approx H(\theta_i) + H_\theta(\theta - \theta_i)$$

这里的 Jacobian：

$$H_\theta$$

就扮演了 local regressor matrix 的角色。

第四类：来自 power-system / DCOPF 这类结构模型。

例如 DC power flow 中，line flow 可能近似写成：

$$f \approx \text{PTDF } p$$

如果我们用一些 observed injections、loads、binding constraints 或 sensitivity quantities 去解释 price、flow 或 dispatch，那么 Φ 的列就来自这些物理量或优化模型导出的 sensitivity。

这时 Φ 不是任意矩阵，而是由：

- 网络拓扑；
- line reactance / admittance；
- PTDF 或 sensitivity matrix；
- load / generation observations；
- constraint status；
- 线性化假设；
- 数据采样方式；

共同决定。

因此建模时要问：

Which physical or statistical mechanism makes these columns relevant to y ?
 Are these columns independently informative?
 Are any columns nearly duplicated or badly scaled?
 Is Φ measured accurately enough to treat it as fixed?

这也把前面讨论的 errors-in-variables 联系起来：如果 Φ 的来源本身有测量误差或模型误差，那么普通 OLS 的“误差只放在 y 上”假设就会变弱。

4.2.6 6. Connecting Φ to Feature Engineering, Extraction, Selection, and Model Selection

First-pass reading note: 这一节主要是帮你把 DATA423 的 feature workflow 和 Roy 的 Φ 串起来。明天如果时间紧，先确保你会 build Φ 、判断 rank/condition、推 normal equations；这一节可以第二遍读，用来加深直觉。

DATA423 里的 feature engineering、feature extraction、feature selection 和 model selection 可以和 least-squares 里的 Φ 完全串起来。它们都在回答同一个问题：

我们到底应该把哪些 columns 放进 Φ ？

可以把流程理解成：

```
raw measurements
-> feature engineering / extraction
-> candidate Phi matrices
-> feature selection
-> model selection
-> final fitted model
```

在 LS 语言里：

$$y \approx \Phi\theta$$

所以任何关于 features 的决定，最后都会变成对 Φ 的列的决定。

4.2.6.1 Feature Engineering: Designing Candidate Columns

Feature engineering 是把原始变量变成更适合建模的变量。放到 Φ 里，就是构造 candidate columns。

例如原始变量是：

$$x_1, \quad x_2$$

最简单的 Φ 可以是：

$$\Phi = \begin{bmatrix} 1 & x_{1,1} & x_{2,1} \\ 1 & x_{1,2} & x_{2,2} \\ \vdots & \vdots & \vdots \\ 1 & x_{1,N} & x_{2,N} \end{bmatrix}$$

如果我们认为有 interaction：

$$x_1 x_2$$

就加一列：

$$\Phi = \begin{bmatrix} 1 & x_{1,1} & x_{2,1} & x_{1,1}x_{2,1} \\ 1 & x_{1,2} & x_{2,2} & x_{1,2}x_{2,2} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{1,N} & x_{2,N} & x_{1,N}x_{2,N} \end{bmatrix}$$

模型变成：

$$y \approx \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2$$

这仍然是 linear least-squares，因为它对参数 θ 是线性的。

常见 feature engineering 操作在 Φ 中的含义：

Feature engineering idea	What happens to Φ
add intercept	add a column of ones
polynomial term x^2	add a column x_j^2
interaction $x_1 x_2$	add a column $x_{1,j} x_{2,j}$
log transform $\log x$	replace/add a column $\log(x_j)$

Feature engineering idea	What happens to Φ
standardise variable	rescale a column of Φ
one-hot encode category	add indicator columns
cyclic time feature	add sin and cos columns

所以 feature engineering 的直觉是：

用 domain knowledge 决定哪些 transformations 可能让 y 更容易由 $\Phi\theta$ 解释。

4.2.6.2 Feature Extraction: Creating a New Representation

Feature extraction 是从原始变量中创造新的变量。它通常更强调“从已有变量中提取更有信息量的表示”。

假设原始数据矩阵是：

$$X \in \mathbb{R}^{N \times p}$$

Feature extraction 可以看成构造一个变换：

$$Z = g(X)$$

然后用：

$$\Phi = Z$$

或者：

$$\Phi = [\mathbf{1}, X, Z]$$

例如 PCA 会把原始变量变成 principal components：

$$Z = XW$$

其中 W 是 learned projection matrix。此时 Φ 的列不再是原始变量，而是 latent directions：

$$\Phi = \begin{bmatrix} z_{1,1} & z_{1,2} & \cdots & z_{1,k} \\ z_{2,1} & z_{2,2} & \cdots & z_{2,k} \\ \vdots & \vdots & & \vdots \\ z_{N,1} & z_{N,2} & \cdots & z_{N,k} \end{bmatrix}$$

这解释了 latent variables 的概念：这些 variables 不是直接测量的，而是从 raw variables 中推断出来的。

Feature extraction 常见目的：

- 让原始变量变得更适合某类模型；
- 把非线性或周期性结构显式表达出来；
- 降低维度；
- 把多个相关变量压缩成少数 latent variables；
- 改善 Φ 的 conditioning。

例如 cyclic time feature：

$$\text{month}_{\sin} = \sin\left(\frac{2\pi(m-1)}{12}\right)$$

$$\text{month}_{\cos} = \cos\left(\frac{2\pi(m-1)}{12}\right)$$

这比直接把 month 写成 1 到 12 更合理，因为 December 和 January 在周期上很近。

4.2.6.3 Feature Selection: Removing Columns from Φ

Feature selection 是决定哪些 columns 应该保留，哪些应该删除。

如果候选矩阵是：

$$\Phi_{\text{candidate}} = \begin{bmatrix} | & | & | & | \\ \phi_1 & \phi_2 & \phi_3 & \phi_4 \\ | & | & | & | \end{bmatrix}$$

feature selection 可能选择：

$$\Phi_{\text{selected}} = \begin{bmatrix} | & | \\ \phi_1 & \phi_3 \\ | & | \end{bmatrix}$$

也就是删除不重要、重复、噪声大或导致 overfitting 的 columns。

为什么这和 LS 很相关？

- 多余 columns 会增加 variance；
- 无关 columns 会让模型学到 spurious pattern；
- 相关 columns 会让 Φ ill-conditioned；
- 太多 columns 会增加 overfitting 风险；
- 透明模型需要较少且有意义的 columns。

几类 feature selection 方法可以翻译成 Φ 语言：

Feature selection type	Φ interpretation
manual selection	人根据 domain knowledge 删除/保留 columns
filter method	先给 columns 排名，再取 top columns
wrapper method	尝试不同 column subsets，用模型表现选
embedded method	模型训练时自动决定哪些 columns 有用
LASSO / ElasticNet	通过 penalty 让部分 coefficients 变小或变成 0

LASSO 的直觉特别容易和 Φ 连接：

$$\min_{\theta} \|y - \Phi\theta\|_2^2 + \lambda\|\theta\|_1$$

如果某个 coefficient：

$$\theta_i = 0$$

那么 Φ 的第 i 列虽然还在数据里，但模型实际没有使用它。

4.2.6.4 Model Selection: Choosing Between Candidate Φ Designs

Feature engineering、extraction 和 selection 会产生很多可能的 Φ ：

$$\Phi_1, \quad \Phi_2, \quad \Phi_3, \quad \dots$$

例如：

$$\Phi_1 = [1, x_1, x_2]$$

$$\Phi_2 = [1, x_1, x_2, x_1x_2]$$

$$\Phi_3 = [1, x_1, x_2, x_1^2, x_2^2, x_1x_2]$$

$$\Phi_4 = [1, T_1(x), T_2(x), T_3(x)]$$

Model selection 就是在这些 candidate models 之间选择：

$$\mathcal{M}_1, \quad \mathcal{M}_2, \quad \mathcal{M}_3, \dots$$

在 regression 里，常用指标包括：

- RMSE;
- MAE;
- R^2 ;
- validation error;
- cross-validation error;
- AIC / BIC when appropriate.

一个重要原则是：不要只看 training residual。

如果只看：

$$\|y_{\text{train}} - \Phi_{\text{train}} \hat{\theta}\|_2^2$$

更复杂的 Φ 通常会更好，因为 columns 更多、模型更灵活。但这不代表它在 unseen data 上更好。

所以要看 validation/test performance：

$$\|y_{\text{valid}} - \Phi_{\text{valid}} \hat{\theta}\|_2^2$$

这正好连接 Roy Smith 后面讲的 regularisation / validation：最小 training error 不等于最好 prediction。

4.2.6.5 One Unified View

可以把这些概念压缩成一张表：

Concept	Question	Effect on Φ
feature engineering	raw variables 应该如何变形?	add/transform columns
feature extraction	能否从 raw variables 中提取更好的表示?	create new columns $Z = g(X)$
feature selection	哪些 columns 应该保留?	remove or downweight columns
model selection	哪个 candidate Φ 泛化最好?	choose between $\Phi_1, \Phi_2, \dots$
regularisation	如何控制复杂度和 instability?	penalise coefficients linked to columns

所以你可以把 Φ 想成一个“建模决策的账本”：

每一列都是一个假设：

`this feature/basis/interaction/latent variable helps explain y.`

如果 Φ 构造得好，LS 会在这些 columns 的 span 里找到合理 projection。如果 Φ 构造得差，LS 仍然会给你一个最小 residual 的解，但那个解可能没有解释力、泛化差、数值不稳，或者参数不可辨识。

实践中，我们通常会在拟合前对 candidate Φ 做一些 EDA，例如检查 variance、correlation、VIF、rank 和 condition number。这部分不是 Roy Smith 这组课的考试主线，但它能帮助你把 DATA423 的 feature workflow 和这里的 Φ 融合起来。详细流程放在 Appendix: Practical EDA for Candidate Φ 。

4.3 Normal Equations

令

$$J(\theta) = \|y - \Phi\theta\|_2^2$$

其中维度通常是：

$$y \in \mathbb{R}^N, \quad \Phi \in \mathbb{R}^{N \times d}, \quad \theta \in \mathbb{R}^d$$

所以：

$$\Phi\theta \in \mathbb{R}^N, \quad y - \Phi\theta \in \mathbb{R}^N$$

目标函数是 residual 的平方长度：

$$J(\theta) = (y - \Phi\theta)^T (y - \Phi\theta) = \|y - \Phi\theta\|_2^2$$

有时 lecture 写成：

$$J(\theta) = (\Phi\theta - y)^T (\Phi\theta - y) = \|\epsilon\|_2^2$$

这两个完全等价，因为：

$$\Phi\theta - y = -(y - \Phi\theta)$$

平方长度不受负号影响。

4.3.1 Matrix Expansion Rules

推导 normal equations 时，最常用的是下面几条规则。

第一，矩阵乘法展开和普通代数很像，但顺序不能乱：

$$(a - b)^T(a - b) = a^T a - a^T b - b^T a + b^T b$$

令

$$a = \Phi\theta, \quad b = y$$

则：

$$\begin{aligned} J(\theta) &= (\Phi\theta - y)^T(\Phi\theta - y) \\ &= (\Phi\theta)^T(\Phi\theta) - (\Phi\theta)^T y - y^T(\Phi\theta) + y^T y \end{aligned}$$

第二，转置乘积要反过来：

$$(AB)^T = B^T A^T$$

所以：

$$(\Phi\theta)^T = \theta^T \Phi^T$$

于是第一项变成：

$$(\Phi\theta)^T(\Phi\theta) = \theta^T \Phi^T \Phi \theta$$

第三，中间两项其实是同一个 scalar。因为

$$(\Phi\theta)^T y$$

是 1×1 标量，而标量等于自己的转置：

$$(\Phi\theta)^T y = ((\Phi\theta)^T y)^T = y^T(\Phi\theta)$$

并且：

$$(\Phi\theta)^T y = \theta^T \Phi^T y$$

所以：

$$-(\Phi\theta)^T y - y^T (\Phi\theta) = -2\theta^T \Phi^T y$$

完整展开为：

$$J(\theta) = \theta^T \Phi^T \Phi \theta - 2\theta^T \Phi^T y + y^T y$$

这就是截图里那一步：

$$(\Phi\theta - y)^T (\Phi\theta - y) = \theta^T \Phi^T \Phi \theta - 2(\Phi\theta)^T y + y^T y$$

也可以把中间项写成 $-2\theta^T \Phi^T y$ ，因为 $(\Phi\theta)^T y = \theta^T \Phi^T y$ 。

4.3.2 Differentiation Rules

接着对 θ 求导。常用规则是：

$$\frac{\partial}{\partial x}(x^T A x) = (A + A^T)x$$

如果 A 是 symmetric，则：

$$\frac{\partial}{\partial x}(x^T A x) = 2Ax$$

在这里：

$$A = \Phi^T \Phi$$

而

$$(\Phi^T \Phi)^T = \Phi^T \Phi$$

所以 $\Phi^T \Phi$ 是 symmetric。

另外：

$$\frac{\partial}{\partial x}(x^T b) = b$$

以及不含 x 的常数项求导为 0。

因此：

$$\begin{aligned}\frac{\partial J}{\partial \theta} &= \frac{\partial}{\partial \theta} (\theta^T \Phi^T \Phi \theta - 2\theta^T \Phi^T y + y^T y) \\ &= 2\Phi^T \Phi \theta - 2\Phi^T y + 0\end{aligned}$$

令 gradient 为 0：

$$2\Phi^T \Phi \theta - 2\Phi^T y = 0$$

两边除以 2：

$$\Phi^T \Phi \theta - \Phi^T y = 0$$

所以：

$$\Phi^T \Phi \theta = \Phi^T y$$

如果 $\Phi^T \Phi$ 可逆：

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y$$

4.3.3 Why the Closed Form Is Not Always How We Compute It

这个公式是 least-squares 的 theoretical solution。它很适合：

- 证明 theorem；
- 理解 estimator 的结构；
- 在小规模、well-conditioned 的例子中手算或教学；
- 帮助看清楚 $\Phi^T \Phi$ 、rank、variance 等概念。

但在实际计算中，不一定应该直接写：

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y$$

原因是 normal equation 先形成了：

$$\Phi^T \Phi$$

这一步会把 singular values 大致平方。直观上：

```
small numbers become smaller
large numbers become larger
```

如果 Φ 本来 scaling 就不好，或者不同列的量级差很多，那么 $\Phi^T \Phi$ 会更 ill-conditioned。

用 condition number 表示，通常有近似关系：

$$\kappa(\Phi^T \Phi) = \kappa(\Phi)^2$$

所以如果 Φ 的 condition number 已经大，normal equation 会把数值问题放大。

接着公式还要求：

$$(\Phi^T \Phi)^{-1}$$

这意味着小的 singular values 在 inverse 里会变成很大的数。于是 tiny numerical errors 或 noisy data 可能被放大，最后影响 $\hat{\theta}$ 。

这就是 lecture 里说的：

```
squared things
small numbers get smaller
big numbers get bigger
then inverted
small numbers may get very big
```

从实践角度，通常更稳的做法是：

- 不显式计算 inverse；
- 用 QR decomposition 或 SVD 解 least-squares；
- 在 MATLAB 里用 backslash，例如 `theta = Phi \ y`；
- 在 Python/NumPy 里用 `lstsq`，而不是手写 inverse；
- 如果问题 ill-conditioned，考虑 scaling、regularisation 或 SVD truncation。

如果是 under-determined case，也就是参数数量比有效数据约束更多：

$$d > N$$

或者 Φ 没有 full column rank，那么：

$$\Phi^T \Phi$$

不可逆或接近不可逆。此时 closed-form inverse 不再是可靠计算方式，甚至不存在。后面讲 regularisation、minimum-norm solution、pseudo-inverse 或 SVD 时，就是在处理这类问题。

Pseudo-inverse 小提示：

如果 Φ 不是 full column rank，不能直接用普通 inverse，但可以用 Moore-Penrose pseudo-inverse：

$$\hat{\theta} = \Phi^+ y$$

其中 Φ^+ 可以通过 SVD 定义。若：

$$\Phi = U \Sigma V^T$$

则：

$$\Phi^+ = V \Sigma^+ U^T$$

Σ^+ 的做法是：把非零 singular values 取倒数，零 singular values 保持为零。

直觉：

- ordinary inverse 只适用于 square 且 nonsingular 的矩阵；
- pseudo-inverse 可以处理 rectangular、under-determined 或 rank-deficient 的 LS 问题；
- 在有多个 exact/least-squares solutions 时，pseudo-inverse 通常给出 minimum-norm solution；
- 如果 singular values 很小，pseudo-inverse 仍可能放大 noise，所以实践中常和 SVD truncation 或 regularisation 一起考虑。

所以 Roy 说 rank deficient 时可以用 pseudo-inverse，意思是：normal-equation inverse 不存在时，仍然可以用 SVD-based generalized inverse 找到一个合理的 LS 解。

所以可以把 normal-equation 解记成：

theoretical solution: useful for understanding and proofs, but not always the numerical algorithm.

注意事项总结：

- normal equations 总是 consistent；
- 但 inverse form 需要 Φ full column rank；
- 如果 $\Phi^T \Phi$ condition number 很大，解会对噪声敏感；
- 实际计算时避免显式求 inverse，优先使用 QR、SVD 或 solver 提供的 least-squares routine；
- under-determined 或 rank-deficient 时，要转向 pseudo-inverse、regularisation 或其他约束。

4.4 Geometric Interpretation

LS 的几何意义是：把 y 投影到 Φ 的 column space 上。残差

$$r = y - \Phi\hat{\theta}$$

与 column space 正交，因此：

$$\Phi^T r = 0$$

也就是：

$$\Phi^T(y - \Phi\hat{\theta}) = 0$$

这正是 normal equations。

记忆方式：**LS** 不是让每个点都正确，而是让误差向量无法再沿模型空间方向减少。

4.5 Linear Function Parametrisation and Basis Functions

Lecture 6 里说的 linear least-squares 不等于“只能拟合直线”。更准确的说法是：

模型对参数 θ 是 linear combination，但每个 basis function $h_i(x)$ 可以是非线性的。

一般写成：

$$y = f(x) = \sum_{i=1}^d h_i(x)\theta_i$$

这里 $h_i(x)$ 是 basis functions， θ_i 是要估计的系数。只要模型对 θ_i 是线性的，就仍然可以放进 linear least-squares 框架。

对数据点 $x_1, \dots, x_N$ ，design matrix 是：

$$\Phi = \begin{bmatrix} h_1(x_1) & h_2(x_1) & \cdots & h_d(x_1) \\ h_1(x_2) & h_2(x_2) & \cdots & h_d(x_2) \\ \vdots & \vdots & & \vdots \\ h_1(x_N) & h_2(x_N) & \cdots & h_d(x_N) \end{bmatrix}$$

于是：

$$y \approx \Phi\theta$$

重点是：非线性可以在 $h_i(x)$ 里，linear 只要求 θ 是线性出现的。

4.5.1 Power Basis

最直接的多项式 basis 是 powers of x ：

$$h_1(x) = 1, \quad h_2(x) = x, \quad h_3(x) = x^2, \quad h_4(x) = x^3, \dots$$

因此三次多项式可以写成：

$$f(x) = \theta_1 + \theta_2 x + \theta_3 x^2 + \theta_4 x^3$$

这不是关于 x 的线性函数，但它仍然是关于参数 θ 的线性组合。

4.5.2 Chebyshev Basis

Chebyshev polynomials 是另一组多项式 basis。它们在区间 $[-1, 1]$ 上特别常用，因为数值性质通常比普通 powers of x 更稳定。

前几项是：

$$T_0(x) = 1$$

$$T_1(x) = x$$

$$T_2(x) = 2x^2 - 1$$

递推关系是：

$$T_{i+1}(x) = 2xT_i(x) - T_{i-1}(x)$$

所以也可以写：

$$f(x) = \theta_1 T_0(x) + \theta_2 T_1(x) + \theta_3 T_2(x) + \dots$$

它和 power basis 的区别不是“能不能用 LS”，而是 Φ 的列长什么样、这些列之间是否容易数值相关、拟合曲线在区间上如何摆动。




图 1: Power basis 和 Chebyshev basis 都可以形成 Φ 的列，但它们产生的曲线形状和数值性质不同。

4.5.3 Why Polynomial Bases Are Not Good for Orbits

多项式 basis 很适合局部拟合曲线，但不适合作为行星或彗星轨道的自然模型。原因是：行星和彗星在经典二体问题下走的是圆锥曲线，而不是一般多项式图像。

圆锥曲线的一般隐式形式是：

$$Ax^2 + Bxy + Cy^2 + Dx + Ey + F = 0$$

这个式子对 x, y 是二次的，但对参数

$$\theta = [A \ B \ C \ D \ E \ F]^T$$

仍然是线性的。把 basis functions 写出来：

$$h(x, y) = [x^2 \ xy \ y^2 \ x \ y \ 1]$$

则每个观测点满足：

$$h(x_j, y_j)\theta \approx 0$$

所以“用圆锥曲线拟合轨道”仍然保留了 linear combination 的思想，只是 basis functions 从

$$1, x, x^2, \dots$$

变成了

$$x^2, xy, y^2, x, y, 1$$

小心一点：如果直接最小化 $\|\Phi\theta\|^2$ ，会得到 trivial solution $\theta = 0$ 。实际 conic fitting 通常需要加 normalization 或 constraint，例如固定某个系数、令 $\|\theta\| = 1$ ，或加入与 ellipse/parabola/hyperbola 类型相关的约束。这里要抓住的主线是：**basis function 改变了可表达的几何形状**。




图 2: 圆、椭圆、抛物线、双曲线都是圆锥曲线。它们不是普通的一元多项式图像，但可以由二次隐式 basis functions 表示。

从图像直觉上看：

- power basis 让函数图像以 $y = f(x)$ 的形式上下弯曲；
- Chebyshev basis 也是多项式，但在 $[-1, 1]$ 上有更规整的振荡结构；
- conic basis 不一定把曲线写成单值函数 $y = f(x)$ ，因此可以表达闭合轨道形状，例如 circle 和 ellipse；
- 对 Ceres/planet orbit 这类问题，conic section 比普通 polynomial 更符合物理几何。

5 Nonlinear Least Squares and Gauss/Ceres

Lecture 6 用 Gauss 预测 Ceres 轨道说明：least squares 不只是 line fitting，也可以处理 nonlinear model。

非线性模型：

$$y_{\text{obs}} = H(\theta, t) + \epsilon$$

目标：

$$\min_{\theta} \frac{1}{2} \epsilon^T \epsilon$$

其中：

$$\epsilon = y_{\text{obs}} - H(\theta, t)$$

非线性 LS 的基本做法：

1. 从 nominal parameter θ_i 开始。
2. 对 $H(\theta)$ 做 Taylor linearisation:

$$H(\theta) \approx H(\theta_i) + H_\theta(\theta - \theta_i)$$

3. 定义：

$$\delta y = y_{\text{obs}} - H(\theta_i), \quad \delta \theta = \theta - \theta_i$$

4. 解线性 LS:

$$\min_{\delta \theta} \|\delta y - H_\theta \delta \theta\|_2^2$$

5. normal equations:

$$H_\theta^T H_\theta \delta \theta = H_\theta^T \delta y$$

6. 更新:

$$\theta_{i+1} = \theta_i + \delta \theta$$

5.1 Why This Is a Gradient / Gauss-Newton Update

Roy 说 Gauss 做的事情 “basically solving the gradient update step”，意思不是普通 gradient descent 那种简单更新：

$$\theta_{i+1} = \theta_i - \alpha \nabla J(\theta_i)$$

而是更接近 **Gauss-Newton**：

在当前点附近把 nonlinear model 线性化，然后解一个 local least-squares problem，得到一个更聪明的 step $\delta \theta$ 。

原始 nonlinear cost 是：

$$J(\theta) = \frac{1}{2} \|y_{\text{obs}} - H(\theta)\|_2^2$$

定义 residual:

$$r(\theta) = y_{\text{obs}} - H(\theta)$$

在当前估计 θ_i 处:

$$r_i = r(\theta_i) = y_{\text{obs}} - H(\theta_i)$$

对模型做一阶 Taylor expansion:

$$H(\theta_i + \delta\theta) \approx H(\theta_i) + H_\theta \delta\theta$$

因此 residual 近似为:

$$r(\theta_i + \delta\theta) = y_{\text{obs}} - H(\theta_i + \delta\theta) \approx y_{\text{obs}} - H(\theta_i) - H_\theta \delta\theta$$

也就是:

$$r(\theta_i + \delta\theta) \approx r_i - H_\theta \delta\theta$$

于是 nonlinear cost 在当前点附近被近似成一个 quadratic cost:

$$J_{\text{quad}}(\delta\theta) = \frac{1}{2} \|r_i - H_\theta \delta\theta\|_2^2$$

这就是 Roy 说的: linearise the nonlinear model, 然后因为 error squared, 所以得到 quadratic approximation to the cost function。

现在问题变成:

$$\min_{\delta\theta} \frac{1}{2} \|r_i - H_\theta \delta\theta\|_2^2$$

这就是一个 ordinary linear least-squares problem, 只不过 unknown 不是 θ , 而是 update step:

$$\delta\theta$$

对应关系是:

Ordinary LS	Gauss-Newton local LS
y	r_i or δy
Φ	H_θ

Ordinary LS	Gauss-Newton local LS
θ	$\delta\theta$
$\min_{\theta} \ y - \Phi\theta\ ^2$	$\min_{\delta\theta} \ r_i - H_{\theta}\delta\theta\ ^2$

对 J_{quad} 求导:

$$\nabla_{\delta\theta} J_{\text{quad}} = -H_{\theta}^T (r_i - H_{\theta}\delta\theta)$$

令 gradient 为 0:

$$-H_{\theta}^T (r_i - H_{\theta}\delta\theta) = 0$$

所以:

$$H_{\theta}^T H_{\theta}\delta\theta = H_{\theta}^T r_i$$

这就是 local normal equations。

如果 $H_{\theta}^T H_{\theta}$ 可逆:

$$\delta\theta = (H_{\theta}^T H_{\theta})^{-1} H_{\theta}^T r_i$$

然后更新:

$$\theta_{i+1} = \theta_i + \delta\theta$$

再在新的 θ_{i+1} 处重新计算:

$$H(\theta_{i+1}), \quad H_{\theta}(\theta_{i+1}), \quad r(\theta_{i+1})$$

然后重复。

所以 Gauss 的迭代可以写成:

```
start with theta_i
-> linearise nonlinear model around theta_i
-> solve a linear LS problem for delta theta
-> update theta_{i+1} = theta_i + delta theta
-> repeat until residual/update is small
```


5.1.1 Gradient Descent vs Gauss-Newton

普通 gradient descent 只用 gradient direction:

$$\theta_{i+1} = \theta_i - \alpha \nabla J(\theta_i)$$

它需要选择 step size α , 而且只知道“往哪里下降”。

Gauss-Newton 更进一步: 它用 Jacobian H_θ 构造一个 local quadratic approximation:

$$J(\theta_i + \delta\theta) \approx J_{\text{quad}}(\delta\theta)$$

然后直接最小化这个 local quadratic model, 得到 step $\delta\theta$ 。

所以它不是“随便走一步”, 而是:

choose the step that would solve the linearised least-squares problem.

这就是 Roy 说 least squares is solving the gradient update step 的意思: 每一次 nonlinear optimisation 的 update step, 本身就是一个 linear least-squares solve。

5.1.2 Why This Matters for Ceres

Gauss 的 Ceres problem 是 nonlinear, 因为 orbital elements 和 observations 的关系不是线性的。直接一次 LS 不能解决完整问题。

但在当前 orbit estimate 附近, 小范围内可以线性化:

$$\text{change in predicted observations} \approx H_\theta \delta\theta$$

于是每次 iteration 都是:

$$\text{observation mismatch} \approx \text{Jacobian} \times \text{parameter update}$$

也就是:

$$\delta y \approx H_\theta \delta\theta$$

通过 LS 找到最能减少 mismatch 的 $\delta\theta$, 再更新 orbit estimate。重复很多次后, 得到高精度 orbit。

这就是:

```
nonlinear orbit estimation
-> repeated linear least-squares updates
-> Gauss-Newton style iteration
```

考试理解重点：

- 三个观测点给 Gauss 一个 nominal orbit，但完整 22 个观测点用于 LS refinement；
- nonlinear LS 每一步只是 local quadratic/linear approximation；
- LS solve 给出的不是最终答案本身，而是当前 iteration 的 update step；
- 不能把一次 linearised solution 当成 global exact solution。

6 Statistical Properties of Least Squares

6.1 Why LS Estimate Is Random

Roy 在 Lecture 7 这里做了一个重要转向：least squares 不再只是 deterministic optimisation，而是 statistical estimation。

Deterministic view 是：

```
given y and Phi
solve for theta_hat
```

也就是：

$$\hat{\theta} = \arg \min_{\theta} \|y - \Phi\theta\|_2^2$$

但实际 measurement data 有误差。Gauss 测 Ceres 的角度时，观测本身就有有限精度；现代 data-driven optimisation 里的 population data 也有 stochastic variation。

所以更合理的 model 是：

$$y = \Phi\theta_0 + \epsilon$$

其中：

- θ_0 是 underlying true parameter；
- ϵ 是 measurement noise / random error；
- y 因为包含 ϵ ，所以是 random；
- Φ 在 standard LS 中先当作 fixed design matrix。

如果 ϵ 是随机噪声，那么

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y$$

也是随机变量。

直接代入：

$$\begin{aligned}\hat{\theta} &= (\Phi^T \Phi)^{-1} \Phi^T (\Phi \theta_0 + \epsilon) \\ &= (\Phi^T \Phi)^{-1} \Phi^T \Phi \theta_0 + (\Phi^T \Phi)^{-1} \Phi^T \epsilon \\ &= \theta_0 + (\Phi^T \Phi)^{-1} \Phi^T \epsilon\end{aligned}$$

所以：

$$\hat{\theta} - \theta_0 = (\Phi^T \Phi)^{-1} \Phi^T \epsilon$$

这说明 $\hat{\theta}$ 的误差完全由 measurement noise 通过 LS estimator 传播而来。

如果重复同一个 experiment，即使 Φ 不变，新的 measurement noise 会产生新的 y ，因此会产生新的 $\hat{\theta}$ 。

这就是 Roy 说：

`theta_hat is a statistical quantity`

的意思。

把 $\hat{\theta}$ 当作 random variable 后，我们才有理由问：

因此考试会关心：

- $\hat{\theta}$ 是否 unbiased；
- variance/covariance 有多大；
- MSE 是否最小；
- correlated noise 时如何调整。

6.2 Bias, Variance, and MSE

Roy 这里强调：MSE 是一个 expectation。它不是某一次 experiment 算出来的单个 squared error，而是在理论上对同一个 data-generating mechanism 下的 repeated sampling / measurement noise 取平均。

实践中，我们当然不会只停留在“想象”。因为真实 data-generating distribution P 不知道，也不能无限重复实验，所以通常用 train/validation/test split、cross-validation 或 bootstrap 去估计这个 expectation。

单次实验中你看到的是：

$$(\hat{\theta} - \theta_0)^2$$

但 MSE 是:

$$E[(\hat{\theta} - \theta_0)^2]$$

这个 expectation 是对 measurement noise / random sampling / repeated experiments 的分布取的。也就是说, MSE 问的是:

on average, how far is my estimator from the true parameter?

如果关心 prediction error, 实践中常用 held-out test set 估计:

$$\widehat{\text{MSE}}_{\text{test}} = \frac{1}{n_{\text{test}}} \sum_{i \in \text{test}} (y_i - \hat{y}_i)^2$$

Cross-validation 则反复切分数据, 计算多个 validation errors, 再取平均:

$$\widehat{\text{CV}} = \frac{1}{K} \sum_{k=1}^K \widehat{\text{MSE}}_{\text{valid},k}$$

所以要区分:

theoretical MSE

-> expectation under the data-generating process

estimated MSE

-> finite-data approximation using validation/test/CV/bootstrap

这里要区分三件事:

- θ_0 是 true parameter, 通常固定但未知;
- $\hat{\theta}$ 是 estimator, 是由 noisy data 算出来的 random variable;
- MSE 是 $\hat{\theta}$ 围绕 θ_0 的 expected squared error。

Bias:

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta_0$$

所以 unbiased 的意思是:

$$E[\hat{\theta}] = \theta_0$$

也就是重复实验很多次后, 估计值的平均会落在 true parameter 上。它比较的是 estimator 的 expectation 和 true parameter, 不是某一次 $\hat{\theta}$ 和 θ_0 是否相等。

6.2.1 Derivation: Why Ordinary LS Is Unbiased

这里的前提是 ordinary least squares 的标准统计模型：

$$y = \Phi\theta_0 + \epsilon$$

其中：

- θ_0 是 true but unknown parameter;
- Φ 被当作 fixed / known design matrix;
- error 加在 y 上;
- $E[\epsilon] = 0$;
- Φ full column rank, 所以 $\Phi^T\Phi$ 可逆。

OLS estimator 是：

$$\hat{\theta} = (\Phi^T\Phi)^{-1}\Phi^Ty$$

把 true data-generating model 代进去：

$$\begin{aligned}\hat{\theta} &= (\Phi^T\Phi)^{-1}\Phi^T(\Phi\theta_0 + \epsilon) \\ &= (\Phi^T\Phi)^{-1}\Phi^T\Phi\theta_0 + (\Phi^T\Phi)^{-1}\Phi^T\epsilon \\ &= \theta_0 + (\Phi^T\Phi)^{-1}\Phi^T\epsilon.\end{aligned}$$

现在对 repeated experiments 取 expectation：

$$\begin{aligned}E[\hat{\theta}] &= E[\theta_0 + (\Phi^T\Phi)^{-1}\Phi^T\epsilon] \\ &= \theta_0 + (\Phi^T\Phi)^{-1}\Phi^TE[\epsilon] \\ &= \theta_0 + (\Phi^T\Phi)^{-1}\Phi^T0 \\ &= \theta_0.\end{aligned}$$

所以：

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta_0 = 0.$$

这就是 ordinary LS unbiased 的推导。

需要注意：unbiasedness 不是说每一次估计都会等于真值，而是说在同一个 data collection mechanism 下重复很多次， $\hat{\theta}$ 的长期平均值等于 θ_0 。

如果 $E[\epsilon] \neq 0$ ，则：

$$E[\hat{\theta}] = \theta_0 + (\Phi^T \Phi)^{-1} \Phi^T E[\epsilon],$$

此时 estimator 一般会 biased。类似地，如果 Φ 本身有 measurement error，或者 ϵ 和 Φ 相关，那么 ordinary LS 的 unbiasedness 推导也会断掉；这就是 errors-in-variables / instrumental variables 要处理的问题之一。

Variance:

$$\text{Var}(\hat{\theta}) = E[(\hat{\theta} - E[\hat{\theta}])^2]$$

Variance 衡量的是 $\hat{\theta}$ 在重复实验中围绕自己的平均值 $E[\hat{\theta}]$ 波动多大。

Mean square error:

$$\text{MSE} = E[(\hat{\theta} - \theta_0)^2]$$

MSE 衡量的是 $\hat{\theta}$ 在重复实验中围绕 true parameter θ_0 的 squared error 平均有多大。Validation/test MSE 则是用 held-out data 估计 prediction error；它更接近 DATA423 model selection 里的实践问题。

注意：MSE 本身是一个 expectation，因此在理论上是一个确定的 quantity，不是 random variable。它包含 variance 部分，但不能简单说 “MSE 具有 variance”。如果我们用有限 validation set、test set 或 repeated resampling 去估计 MSE，那么那个 estimated MSE 才会因为样本有限而有 sampling variability。

核心关系：

$$\text{MSE} = \text{bias}^2 + \text{variance}$$

6.2.2 Derivation: Why MSE = Bias Squared + Variance

先看 scalar estimator 的情况。令：

$$\mu_{\hat{\theta}} = E[\hat{\theta}]$$

MSE 定义为：

$$\text{MSE} = E[(\hat{\theta} - \theta_0)^2]$$

在括号里加减同一个量 $E[\hat{\theta}]$ ：

$$\hat{\theta} - \theta_0 = (\hat{\theta} - E[\hat{\theta}]) + (E[\hat{\theta}] - \theta_0)$$

所以：

$$\begin{aligned}\text{MSE} &= E \left[\left((\hat{\theta} - E[\hat{\theta}]) + (E[\hat{\theta}] - \theta_0) \right)^2 \right] \\ &= E[(\hat{\theta} - E[\hat{\theta}])^2] + 2(E[\hat{\theta}] - \theta_0)E[\hat{\theta} - E[\hat{\theta}]] + (E[\hat{\theta}] - \theta_0)^2\end{aligned}$$

中间项为 0，因为：

$$E[\hat{\theta} - E[\hat{\theta}]] = E[\hat{\theta}] - E[\hat{\theta}] = 0$$

因此：

$$\text{MSE} = E[(\hat{\theta} - E[\hat{\theta}])^2] + (E[\hat{\theta}] - \theta_0)^2$$

也就是：

$$\text{MSE} = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2$$

这就是 Roy 提到的 result。

向量参数时，常见写法是看 squared norm：

$$\text{MSE} = E[\|\hat{\theta} - \theta_0\|_2^2]$$

对应分解为：

$$\text{MSE} = \text{tr}(\text{Cov}(\hat{\theta})) + \|\text{Bias}(\hat{\theta})\|_2^2$$

所以同样的直觉仍然成立：

```
total expected squared error
= variance part
+ systematic bias part
```

易错点：unbiased 不等于 minimum MSE。Unbiased 只是 bias 为 0，但 MSE 还包括 variance。

6.3 Statistical Consistency

Roy 这里提醒：consistency 有两个不同意思。

前面讲 normal equations 时，consistent 是线性代数里的意思：

the equation has at least one solution

例如 normal equations:

$$\Phi^T \Phi \theta = \Phi^T y$$

总是 algebraically consistent, 因为右边 $\Phi^T y$ 一定在 $\Phi^T \Phi$ 的 range 里。

但在 statistics 里, consistency 是 estimator 的性质。它问的是:

as sample size grows, does the estimator concentrate around the true value?

如果 $\hat{\theta}_N$ 是用 N 个 observations 算出来的 estimator, 那么 consistency 通常写成:

$$\hat{\theta}_N \xrightarrow{p} \theta_0$$

意思是对任意 fixed tolerance $\delta > 0$:

$$P(\|\hat{\theta}_N - \theta_0\| > \delta) \rightarrow 0 \quad \text{as } N \rightarrow \infty.$$

用 Roy 的话说:

as you take more and more data,
the probability of making a big error goes to zero.

也就是说, $\hat{\theta}_N$ 的 distribution 会越来越集中在 true parameter θ_0 附近。不是说每个 finite-sample estimate 都等于 θ_0 , 而是说随着 data 增加, large error 的概率消失。

6.3.1 Relation to Bias and Variance

Unbiasedness 和 consistency 不是同一个概念。

Unbiasedness 是 finite-sample expectation statement:

$$E[\hat{\theta}_N] = \theta_0.$$

Consistency 是 large-sample probability statement:

$$P(\|\hat{\theta}_N - \theta_0\| > \delta) \rightarrow 0.$$

一个 estimator 可以 finite-sample biased, 但仍然 consistent, 只要 bias 随 N 增加消失, variance 也收缩。Regularised estimators 就经常要从这个角度看: finite sample 里可能 biased, 但如果 regularisation 随 data size 合理减小, 仍可能 consistent。

对 ordinary LS, 在标准条件下, 如果:

- $E[\epsilon] = 0$;
- regressors 和 error 没有 problematic correlation;
- $\Phi^T \Phi$ 随着 N 增加提供越来越多 information;
- 没有 rank deficiency 持续存在;

那么更多 data 会让 estimator distribution 收缩, $\hat{\theta}_N$ 会越来越接近 θ_0 。

6.3.2 One-line Distinction

algebraic consistency:

an equation has a solution

statistical consistency:

an estimator converges to the true value as data increases

6.4 BLUE

BLUE = Best Linear Unbiased Estimator。

如果噪声 zero mean 且 covariance 为 R :

$$E[\epsilon\epsilon^T] = R$$

则 BLUE:

$$\hat{\theta}_{\text{BLUE}} = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} y$$

其 covariance:

$$\text{Cov}(\hat{\theta}_{\text{BLUE}}) = (\Phi^T R^{-1} \Phi)^{-1}$$

当 $R = \sigma^2 I$ 时, BLUE 退化为普通 LS。

6.5 Variance and Signal-to-Noise Ratio

Roy 说 estimator variance 本质上是在告诉你 inverse signal-to-noise ratio。可以从最简单的一参数模型看出来。

假设:

$$y = \phi\theta + \epsilon$$

其中:

$$\phi = \begin{bmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_N \end{bmatrix}, \quad E[\epsilon] = 0, \quad \text{Cov}(\epsilon) = \sigma^2 I.$$

OLS estimator 是:

$$\hat{\theta} = (\phi^T \phi)^{-1} \phi^T y$$

把 true model 代入:

$$\begin{aligned} \hat{\theta} &= (\phi^T \phi)^{-1} \phi^T (\phi\theta + \epsilon) \\ &= (\phi^T \phi)^{-1} \phi^T \phi\theta + (\phi^T \phi)^{-1} \phi^T \epsilon \\ &= \theta + (\phi^T \phi)^{-1} \phi^T \epsilon. \end{aligned}$$

所以估计误差是:

$$\hat{\theta} - \theta = (\phi^T \phi)^{-1} \phi^T \epsilon.$$

现在计算 variance。使用规则:

$$\text{Var}(A\epsilon) = A \text{Cov}(\epsilon) A^T$$

这里:

$$A = (\phi^T \phi)^{-1} \phi^T$$

因此:

$$\begin{aligned} \text{Var}(\hat{\theta}) &= (\phi^T \phi)^{-1} \phi^T (\sigma^2 I) \phi (\phi^T \phi)^{-1} \\ &= \sigma^2 (\phi^T \phi)^{-1} \phi^T \phi (\phi^T \phi)^{-1} \\ &= \sigma^2 (\phi^T \phi)^{-1}. \end{aligned}$$

因为这里是 scalar one-regressor case:

$$\phi^T \phi = \sum_{i=1}^N \phi_i^2$$

所以:

$$\text{Var}(\hat{\theta}) = \frac{\sigma^2}{\sum_{i=1}^N \phi_i^2}.$$

这就是 signal-to-noise ratio 的直觉:

```
noise power      = sigma^2
regressor signal = sum phi_i^2
estimator variance = noise power / regressor signal
```

因此:

$$\text{Var}(\hat{\theta}) \propto \frac{1}{\text{SNR}}.$$

如果 ϕ 的 magnitude 大、variation 充分, 那么:

$$\sum_i \phi_i^2 \text{ large} \Rightarrow \text{Var}(\hat{\theta}) \text{ small}.$$

如果 ϕ 很小、变化不足, 或者所有 observation 都集中在很窄的范围内, 那么:

$$\sum_i \phi_i^2 \text{ small} \Rightarrow \text{Var}(\hat{\theta}) \text{ large}.$$

直觉上, 如果你想估计 slope, 但 input/regressor 几乎不动, 那么一点点 output noise 就会让 slope estimate 大幅摆动。反过来, 如果 regressor 覆盖范围很大, signal 很强, 同样的 noise 对 estimate 的影响就小很多。

对多参数模型:

$$\text{Cov}(\hat{\theta}) = \sigma^2 (\Phi^T \Phi)^{-1}$$

扮演同样角色。 $\Phi^T \Phi$ 描述 regressor signal 在不同 parameter directions 上有多强; 如果某些方向 signal weak 或 columns nearly dependent, 那么 $(\Phi^T \Phi)^{-1}$ 会很大, estimate variance 也会很大。

6.6 Worked Exercise: Inverse-variance Weighting

Roy 说 “things that have small variance are valuable estimates”, 对应的标准推导就是 inverse-variance weighting。这个很可能作为 BLUE 的基础推导题出现。

假设我们有 n 个 independent unbiased estimates:

$$\hat{\theta}_1, \dots, \hat{\theta}_n$$

其中:

$$E[\hat{\theta}_i] = \theta, \quad \text{Var}(\hat{\theta}_i) = \sigma_i^2.$$

我们把它们线性组合:

$$\hat{\theta}_w = \sum_{i=1}^n w_i \hat{\theta}_i.$$

6.6.1 Step 1: Unbiasedness Constraint

先计算 expectation:

$$\begin{aligned} E[\hat{\theta}_w] &= E \left[\sum_{i=1}^n w_i \hat{\theta}_i \right] \\ &= \sum_{i=1}^n w_i E[\hat{\theta}_i] \\ &= \sum_{i=1}^n w_i \theta \\ &= \theta \sum_{i=1}^n w_i. \end{aligned}$$

如果希望 $\hat{\theta}_w$ unbiased, 就要:

$$E[\hat{\theta}_w] = \theta.$$

因此:

$$\theta \sum_{i=1}^n w_i = \theta$$

所以 constraint 是:

$$\sum_{i=1}^n w_i = 1.$$

6.6.2 Step 2: Variance of the Weighted Estimate

因为 estimates independent:

$$\text{Var} \left(\sum_{i=1}^n w_i \hat{\theta}_i \right) = \sum_{i=1}^n w_i^2 \text{Var}(\hat{\theta}_i).$$

所以:

$$\text{Var}(\hat{\theta}_w) = \sum_{i=1}^n w_i^2 \sigma_i^2.$$

BLUE 的问题就是:

$$\min_{w_1, \dots, w_n} \sum_{i=1}^n w_i^2 \sigma_i^2 \quad \text{subject to} \quad \sum_{i=1}^n w_i = 1.$$

6.6.3 Step 3: Lagrangian

写 Lagrangian:

$$L(w, \lambda) = \sum_{i=1}^n w_i^2 \sigma_i^2 + \lambda \left(\sum_{i=1}^n w_i - 1 \right).$$

对 w_i 求偏导:

$$\frac{\partial L}{\partial w_i} = 2w_i \sigma_i^2 + \lambda.$$

令一阶条件为 0:

$$2w_i \sigma_i^2 + \lambda = 0.$$

所以:

$$w_i = -\frac{\lambda}{2\sigma_i^2}.$$

现在令:

$$c = -\frac{\lambda}{2}.$$

那么：

$$w_i = \frac{c}{\sigma_i^2}.$$

这一步说明，optimal weight 一定和 $1/\sigma_i^2$ 成比例：

$$w_i \propto \frac{1}{\sigma_i^2}.$$

6.6.4 Step 4: Use the Constraint to Find c

我们还不知道 c 。用 unbiasedness constraint：

$$\sum_{i=1}^n w_i = 1.$$

代入：

$$w_i = \frac{c}{\sigma_i^2}$$

得到：

$$\sum_{i=1}^n \frac{c}{\sigma_i^2} = 1.$$

因为 c 对所有 i 都相同，所以可以提出来：

$$c \sum_{i=1}^n \frac{1}{\sigma_i^2} = 1.$$

因此：

$$c = \frac{1}{\sum_{j=1}^n 1/\sigma_j^2}.$$

把 c 放回：

$$w_i = \frac{c}{\sigma_i^2}$$

得到：

$$w_i = \frac{1}{\sigma_i^2} \frac{1}{\sum_{j=1}^n 1/\sigma_j^2}.$$

也就是：

$$w_i = \frac{1/\sigma_i^2}{\sum_{j=1}^n 1/\sigma_j^2}.$$

这就是 inverse-variance weighting。

6.6.5 Step 5: Interpretation

如果 σ_i^2 很大：

$$\frac{1}{\sigma_i^2} \text{ is small} \Rightarrow w_i \text{ is small.}$$

如果 σ_i^2 很小：

$$\frac{1}{\sigma_i^2} \text{ is large} \Rightarrow w_i \text{ is large.}$$

所以：

```
high variance estimate -> unreliable -> small weight
low variance estimate  -> valuable   -> large weight
```

注意，不是把 high-variance estimates 扔掉，而是降低它们的权重。它们仍然包含信息，只是信息质量较低。

6.7 Why Least Squares Does the Weighting in One Shot

Roy 接着说：我们可以先对每个 measurement 单独算一个 slope estimate，再用 inverse-variance weighting 平均；但 least squares 可以一次性做到同样的事。

这句话的背景是一个 scalar gain model：

$$y_i = x_i g + \epsilon_i, \quad \epsilon_i \sim (0, \sigma^2).$$

如果只用第 i 个 measurement，可以得到一个单点 slope estimate：

$$\hat{g}_i = \frac{y_i}{x_i}.$$

因为:

$$y_i = x_i g + \epsilon_i$$

所以:

$$\hat{g}_i = \frac{x_i g + \epsilon_i}{x_i} = g + \frac{\epsilon_i}{x_i}.$$

因此:

$$\text{Var}(\hat{g}_i) = \text{Var}\left(\frac{\epsilon_i}{x_i}\right) = \frac{\sigma^2}{x_i^2}.$$

这说明:

```
large |x_i| -> small slope-estimate variance -> more informative
small |x_i| -> large slope-estimate variance -> less informative
```

如果手工做 inverse-variance weighting, 权重是:

$$w_i = \frac{1/\text{Var}(\hat{g}_i)}{\sum_j 1/\text{Var}(\hat{g}_j)}.$$

代入:

$$\text{Var}(\hat{g}_i) = \frac{\sigma^2}{x_i^2}$$

得到:

$$\begin{aligned} w_i &= \frac{1/(\sigma^2/x_i^2)}{\sum_j 1/(\sigma^2/x_j^2)} \\ &= \frac{x_i^2/\sigma^2}{\sum_j x_j^2/\sigma^2} \\ &= \frac{x_i^2}{\sum_j x_j^2}. \end{aligned}$$

所以手工 BLUE estimate 是:

$$\begin{aligned}
 \hat{g}_{\text{BLUE}} &= \sum_i w_i \hat{g}_i \\
 &= \sum_i \frac{x_i^2}{\sum_j x_j^2} \frac{y_i}{x_i} \\
 &= \frac{\sum_i x_i y_i}{\sum_j x_j^2}.
 \end{aligned}$$

现在看 ordinary least squares。把所有 observations 写成：

$$y = xg + \epsilon$$

其中：

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}.$$

OLS 直接给：

$$\hat{g}_{\text{LS}} = (x^T x)^{-1} x^T y.$$

因为：

$$x^T x = \sum_i x_i^2, \quad x^T y = \sum_i x_i y_i,$$

所以：

$$\hat{g}_{\text{LS}} = \frac{\sum_i x_i y_i}{\sum_i x_i^2}.$$

这和手工 inverse-variance weighted average 完全一样：

$$\hat{g}_{\text{LS}} = \hat{g}_{\text{BLUE}}.$$

这就是 Roy 说 LS “does it in one shot” 的意思：

```

manual route:
  individual slope estimates
  -> compute each variance
  -> inverse-variance weights

```

```

-> weighted average

least-squares route:
  write y = xg + epsilon
  -> solve normal equation
  -> same weighted average appears automatically

```

6.7.1 What Does “Automatically” Mean?

这里的 automatically 不是说 LS 神奇地知道所有 noise variance，而是说：

under the standard homoskedastic noise assumption, the algebra of LS already gives each observation influence proportional to its information content.

在这个 scalar gain example 里，information content 来自 x_i^2 。同样的 output noise σ^2 下，larger $|x_i|$ 给出的 slope estimate variance 更小，所以 LS 解中它的 effective weight 更大。

也可以把 LS 写成：

$$\hat{g}_{\text{LS}} = \sum_i \left(\frac{x_i^2}{\sum_j x_j^2} \right) \left(\frac{y_i}{x_i} \right).$$

括号里的第一项就是 weight，第二项就是单点 slope estimate。

6.7.2 Is This a General Property?

Yes, but with an important qualification.

For ordinary LS, the Gauss-Markov result says: 如果 errors zero mean、uncorrelated、same variance，并且 Φ full column rank，那么 OLS is BLUE。也就是说，在这些假设下，OLS 自动给出 best linear unbiased estimator。

但如果 measurement noise 的 variance 不相同：

$$\text{Cov}(\epsilon) = R \neq \sigma^2 I$$

ordinary LS 不再自动给正确的 noise weighting。这时需要 weighted / generalized least squares：

$$\hat{\theta}_{\text{BLUE}} = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} y.$$

这里的 R^{-1} 才是显式的 inverse-noise-covariance weighting：

```
low noise variance -> larger weight
high noise variance -> smaller weight
correlated noise   -> account for correlation structure
```

所以要分清两层：

```
ordinary LS:
    automatically weights information through Phi under equal-noise assumptions

weighted / generalized LS:
    explicitly weights measurements using R^{-1} when noise variances/correlations differ
```

这也是为什么 Roy 先用 inverse-variance weighting 讲直觉，再说 LS 一步就做到：在标准条件下，normal equations 已经把同一个 BLUE 结果编码进去了。

6.8 Correlated Noise: White Noise vs General BLUE

Roy 后面说，如果 noise 之间有 correlation，electrical engineer 会说 noise has frequency content。直觉是：

```
white noise:
    no time/sample-to-sample correlation
    no preferred frequency structure

correlated noise:
    errors have pattern, memory, drift, oscillation, or frequency content
```

在 ordinary LS 的标准 white-noise case：

$$\text{Cov}(\epsilon) = \sigma^2 I.$$

这里的 identity matrix 表示：

- 每个 measurement noise variance 相同；
- 不同 measurements 的 errors uncorrelated；
- covariance matrix 没有 off-diagonal structure。

这时 ordinary LS：

$$\hat{\theta}_{\text{OLS}} = (\Phi^T \Phi)^{-1} \Phi^T y$$

就是 BLUE。

但如果：

$$\text{Cov}(\epsilon) = R$$

其中 R 不是 $\sigma^2 I$, 例如:

$$R = \begin{bmatrix} \sigma_1^2 & r_{12} & \cdots \\ r_{21} & \sigma_2^2 & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix},$$

那么 off-diagonal entries 表示:

$$E[\epsilon_i \epsilon_j] \neq 0.$$

也就是说, 第 i 个 error 和第 j 个 error 不是独立乱动, 而是有共同变化结构。

普通 LS 在这个情况下通常仍然 unbiased, 但不再是 minimum-variance unbiased estimator。BLUE 变成:

$$\hat{\theta}_{\text{BLUE}} = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} y.$$

这里的 R^{-1} 是 inverse covariance weighting。它的作用不是简单地给每个 point 一个 scalar weight, 而是按整个 noise covariance structure 重新度量 residual:

$$\min_{\theta} (y - \Phi\theta)^T R^{-1} (y - \Phi\theta).$$

如果 $R = \sigma^2 I$, 则:

$$R^{-1} = \frac{1}{\sigma^2} I.$$

这个 scalar factor 会在 normal equations 中 cancel 掉, 所以退化回 ordinary LS。

6.8.1 Correlation vs Independence

Roy 提到可以查 correlation 和 independence 的区别。大致关系是:

independence is stronger than zero correlation.

如果两个 random variables independent, 那么它们没有任何 probabilistic dependence。知道一个变量的值, 不会改变另一个变量的 distribution。

如果两个变量 uncorrelated, 只表示它们的 linear covariance 为 0:

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = 0.$$

这排除了 linear relationship, 不排除 nonlinear relationship。

例如:

$$X \sim \text{symmetric around } 0, \quad Y = X^2.$$

则 Y 完全由 X 决定, 所以它们绝对不 independent。但由于 symmetry, 可能有:

$$\text{Cov}(X, Y) = \text{Cov}(X, X^2) = 0.$$

所以:

```
independent -> uncorrelated
uncorrelated -> not necessarily independent
```

在 Gaussian/noise modelling 里有一个特殊好处: 如果 variables jointly Gaussian, 那么 zero covariance implies independence。这也是为什么 Gaussian white noise 是一个很强、很方便的假设。

6.8.2 Exam Risk

这部分中高概率会考, 因为它直接连接 Roy 的 BLUE 结论。

高概率考法:

- 识别 ordinary LS 什么时候是 BLUE;
- 写出 correlated noise 下的 BLUE;
- 解释 R^{-1} 的作用;
- 说明如果 $R = \sigma^2 I$, BLUE 退化为 ordinary LS;
- 解释为什么实践中难点是估计 R 。

较低概率考法:

- 完整证明该 estimator 在所有 unbiased linear estimators 中 covariance 最小。

考试题型:

- 证明 $Z^T \Phi = I$ 是 linear estimator $\hat{\theta} = Z^T y$ unbiased 的条件;
- 推导 $\text{Cov}(\hat{\theta}) = Z^T R Z$;
- 写出 BLUE;
- 解释为什么 low variance measurement 权重更大。

7 Regularisation and Validation

7.1 Why Regularisation Is Needed

普通 LS 给出 best linear unbiased estimate, 但未必最小化 MSE。Regularisation 的作用:

- 降低 variance;
- 改善 ill-conditioned problem;
- 用一点 bias 换更好的 prediction。

Regularised LS:

$$\min_{\theta} \|y - \Phi\theta\|_2^2 + \eta\|\theta\|_2^2$$

解为:

$$\hat{\theta} = (\Phi^T\Phi + \eta I)^{-1}\Phi^T y$$

当 $\eta = 0$, 回到 ordinary LS。随着 η 增大:

- solution 被 shrink;
- variance 下降;
- bias 上升;
- conditioning 变好。

7.2 Bias-variance Tradeoff

Roy 在这里问了一个很关键的问题:

When choosing an estimator, what are we actually trying to minimise?

候选目标至少有三个:

Objective	What it asks for	Typical tool
minimise bias	make $E[\hat{\theta}]$ close to θ_0	unbiased estimator
minimise variance	make $\hat{\theta}$ stable across repeated experiments	BLUE, inverse-variance weighting
minimise MSE	minimise total expected squared error	regularisation / shrinkage

它们之间的关系是:

$$\text{MSE} = \text{Bias}^2 + \text{Variance}$$

所以 minimum variance 不一定 minimum MSE, zero bias 也不一定 minimum MSE。

7.2.1 What BLUE Optimises

BLUE means:

Best Linear Unbiased Estimator

这里的 “Best” 不是所有意义下都最好, 而是在一个受限集合里最好:

among linear unbiased estimators,
choose the one with minimum variance

也就是说 BLUE 的逻辑是:

force bias = 0, then minimise variance.

所以 ordinary LS / weighted LS 这条线非常适合:

- 参数 θ 本身有物理、工程或经济解释;
- 你希望长期平均估计值等于 true parameter;
- 你要在 unbiased 这个约束下让 estimate 尽量稳定。

但它不保证 minimum MSE, 因为它不允许用 bias 换 variance。

7.2.2 What Minimum MSE Optimises

Minimum MSE 的目标是:

$$\min E[(\hat{\theta} - \theta_0)^2]$$

它允许:

small bias increase
-> larger variance decrease
-> lower total MSE

这就是 shrinkage / regularisation 的思想。Ridge regularisation 会把 coefficient 往 0 拉:

$$\hat{\theta}_\eta = (\Phi^T \Phi + \eta I)^{-1} \Phi^T y$$

它通常不再 unbiased, 但可能有更小的 MSE, 尤其是在:

- data noisy;
- columns of Φ highly correlated;
- $\Phi^T \Phi$ ill-conditioned;
- number of features large;
- prediction on future data 比解释 exact parameter 更重要。

Roy 后面说的 counterintuitive point 就是:

best fit to the experimental data is not necessarily best expected fit to future data.

普通 LS 很擅长 fit 当前 training data, 并且在标准假设下给出 BLUE。但 prediction 目标更关心 future/new data 上的 expected error, 这时 minimum MSE 往往比 strict unbiasedness 更重要。

7.2.3 Connection to Data Mining / Model Selection

这和 data mining 里学的 train / validation / test split 是同一条思想线。

training error

-> how well the model fits the data used to estimate theta

validation error

-> how well a chosen model complexity / eta predicts unseen data

test error

-> final estimate of generalisation performance

在 data mining 语言里:

Statistical language	Data mining language
low bias	model flexible enough to capture signal
high bias	underfitting
high variance	overfitting / unstable model
regularisation	complexity control
validation	choose model complexity / hyperparameter
test error	estimate out-of-sample performance

因此 Roy 这里的 tradeoff 可以翻译成:

too simple model:

high bias, low variance, underfit

too flexible model:

low training error, low bias on training structure, high variance, overfit


```
regularised / selected model:
    controlled bias, controlled variance, better validation/test error
```

所以如果目标是 scientific parameter estimation, unbiased/BUE 很有吸引力; 如果目标是 prediction, minimum MSE 和 validation 通常更关键。

7.2.4 Practical Rule of Thumb

```
If theta itself is the object of interest:
    care strongly about unbiasedness and covariance.

If future prediction is the object of interest:
    care strongly about MSE / validation error.

If Phi is ill-conditioned:
    regularisation may be needed even before prediction quality is considered.
```

Regularisation 的核心不是让 training error 最小, 而是让 expected prediction error 更好。

记忆方式:

```
eta small -> flexible estimate, low bias, high variance
eta large -> shrunk estimate, higher bias, lower variance
best eta  -> balance point for MSE/prediction
```

7.3 Validation

选择 η 时不能只看 fitting data residual。正确思路:

1. 把 data 分成 fitting/training set 和 validation set。
2. 对不同 η 用 fitting set 拟合。
3. 用 validation set 测试 prediction error。
4. 选择 validation error 最小的 η 。

考试可能问:

- 为什么 validation data 不能参与 fitting;
- 为什么 best training fit 不一定 best prediction;
- regularisation 如何连接到 minimum MSE。

8 Convex Sets and Convex Optimisation

8.1 Convex Set

集合 C convex, 如果:

$$x_1, x_2 \in C, \quad \gamma \in [0, 1] \quad \Rightarrow \quad \gamma x_1 + (1 - \gamma)x_2 \in C$$

直觉: 任意两点连线都在集合里。

重要例子:

- hyperplane: $\{x \mid a^T x = b\}$;
- halfspace: $\{x \mid a^T x \leq b\}$;
- norm ball: $\{x \mid \|x - x_c\| \leq r\}$;
- polyhedron: linear inequalities/equalities 的交集;
- ellipsoid:

$$\{x \mid (x - x_c)^T P^{-1}(x - x_c) \leq 1\}$$

重要性质: convex sets 的 intersection 仍然 convex。

8.2 Cones and PSD Cone

Cone:

$$x \in C, \quad \gamma \geq 0 \Rightarrow \gamma x \in C$$

Convex cone 还要求 conic combination 也在集合内。

Positive semidefinite cone:

$$S_+^n = \{X \in S^n \mid X \succeq 0\}$$

PSD 的等价理解:

$$z^T X z \geq 0 \quad \text{for all } z$$

或所有 eigenvalues 非负。

易错点:

- positive semidefinite: eigenvalues ≥ 0 ;
- positive definite: eigenvalues > 0 ;
- cone 不自动 convex。

8.3 Convex Optimisation Problem

标准形式:

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{subject to} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b \end{aligned}$$

其中:

- f_0 和 f_i convex;
- equality constraints 必须 affine。

为什么重要: convex problem 的 local information 可以支持 global solution, solver 更可靠。

9 Problem Classes: LP, QP, SOCP, QCQP, SDP

9.1 Linear Program

LP:

$$\begin{aligned} \min_x \quad & c^T x + d \\ \text{subject to} \quad & Gx \leq h \\ & Ax = b \end{aligned}$$

特征:

- linear cost;
- linear constraints;
- feasible region 是 polytope/polyhedron。

例子: diet problem、logistics、Chebyshev center。

9.2 Quadratic Program

QP:

$$\begin{aligned}
& \min_x \quad \frac{1}{2}x^T Px + c^T x + d \\
& \text{subject to} \quad Gx \leq h \\
& \quad \quad \quad Ax = b
\end{aligned}$$

特征:

- quadratic cost;
- linear constraints。

例子:

- constrained least squares;
- portfolio optimisation;
- simple MPC。

9.3 Second-order Cone Problem

SOCP 典型 constraint:

$$\|A_i x + b_i\|_2 \leq c_i^T x + d_i$$

特征:

- linear objective 常见;
- feasible region 是 second-order cones 的 intersection;
- QP 有时可以 reformulate 成 SOCP。

9.4 QCQP

QCQP:

$$\begin{aligned}
& \min_x \quad \frac{1}{2}x^T P_0 x + q_0^T x + r_0 \\
& \text{subject to} \quad \frac{1}{2}x^T P_i x + q_i^T x + r_i \leq 0
\end{aligned}$$

如果 P_i 满足相应 convexity 条件, feasible region 可以理解为 ellipsoids 的 intersection。

9.5 SDP and LMI

Semidefinite program 的核心是 matrix-valued affine constraint:

$$x_1 F_1 + \cdots + x_N F_N + G \preceq 0$$

这就是 Linear Matrix Inequality。

考试分类技巧：

```
linear cost + linear constraints -> LP
quadratic cost + linear constraints -> QP
norm cone constraints -> SOCP
quadratic constraints -> QCQP
PSD matrix constraints -> SDP/LMI
finite horizon dynamic optimisation -> MPC, often QP
```

10 LMI and Schur Complement

10.1 What Is an LMI?

LMI 是这样的约束：

$$F(x) = F_0 + x_1 F_1 + \cdots + x_n F_n \succeq 0$$

其中矩阵对变量是 affine 的。

它重要是因为很多看起来 nonlinear 的 constraint 可以写成 PSD matrix constraint。

10.2 Schur Complement

典型形式：

$$\begin{bmatrix} Q & S \\ S^T & R \end{bmatrix} \succ 0$$

在 $R \succ 0$ 时，等价于：

$$Q - SR^{-1}S^T \succ 0$$

考试中 Schur complement 常用于：

- 把 norm constraint 写成 LMI;
- 把 quadratic inequality 写成 LMI;

- 处理 stability 和 controller synthesis 中的 matrix inequalities。

易错点：使用 Schur complement 时必须检查 block 的 definiteness 条件。

10.3 Stability LMIs

Continuous-time system:

$$\frac{d}{dt}x(t) = Ax(t)$$

stable iff exists $P \succ 0$ such that:

$$A^T P + P A \prec 0$$

Discrete-time system:

$$x_{k+1} = Ax_k$$

stable iff exists $P \succ 0$ such that:

$$A^T P A - P \prec 0$$

State feedback:

$$u_k = Kx_k$$

closed-loop:

$$x_{k+1} = (A + BK)x_k$$

控制设计中常用变量替换，例如 $V = KY$ ，把对 K 和 Lyapunov matrix 的非线性耦合变成 LMI。

11 Model Predictive Control

11.1 Core Idea

MPC 的基本循环：

1. measure or estimate current state;

2. optimise future state/input trajectory over horizon M ;
3. apply only the first input;
4. move one time step and repeat.

一句话记忆: **plan a full future, execute the first move, then replan.**

11.2 Mathematical Formulation

Dynamics:

$$x_{k+1} = Ax_k + Bu_k + Fw_k$$

Finite horizon cost:

$$J(u, x) = \sum_{i=0}^{M-1} (x_i^T Q x_i + u_i^T R u_i) + x_M^T Q_{\text{terminal}} x_M$$

Typical MPC problem:

$$\begin{aligned} \min_{x, u} \quad & J(u, x) \\ \text{subject to} \quad & x_{k+1} = Ax_k + Bu_k + Fw_k \\ & u_{\text{lb}} \leq u_k \leq u_{\text{ub}} \\ & x_k \in X_{\text{operating}} \\ & x_M \in X_{\text{terminal}} \end{aligned}$$

重要理解:

- dynamics 是 constraints;
- decision variables 通常包括 future inputs 和 future states;
- disturbance forecast 可以作为 feedforward information;
- repeated measurement/re-estimation 提供 feedback。

11.3 Hard, Soft, and Terminal Constraints

Hard constraints:

- 必须满足;
- 例子: actuator limits、safety limits。

Soft constraints:

- 想满足, 但允许违反;

- 通过 penalty cost 处理;
- 例子: building temperature comfort band。

Terminal constraints:

- 规定 horizon 末端状态;
- 用于 recursive feasibility 和 closed-loop stability;
- 常见选择是 invariant terminal set。

11.4 Explicit MPC

Online MPC 每个 time step 求解 optimisation。Explicit MPC 先离线解 parametric optimisation, 把 state space 切成 regions:

- 每个 region 有一个对应的 affine feedback law;
- online 时只判断当前 state 落在哪个 region;
- 很快, 但 regions 数量可能指数增长。

适用场景:

- low-dimensional system;
- extremely high-speed control;
- embedded controller。

不适合:

- 高维系统;
- long horizon;
- constraints 很多导致 regions 爆炸。

12 Tutorial and Exercise Route

12.1 LS Exercises

重点题型:

1. BLUE proof

- unbiased condition: $Z^T \Phi = I$;
- covariance: $\text{Cov}(\hat{\theta}) = Z^T R Z$;
- BLUE estimator:

$$\hat{\theta}_Z = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} Y$$

2. Polynomial and basis-function fitting

- 根据 basis functions 建立 design matrix;
 - 判断 $X^T X$ 是否 nonsingular;
 - radial basis functions 与 kernel matrix。
3. Conic section fitting
- 建立 parameter vector;
 - 固定 scaling, 例如令 $f = 1$;
 - 判断 ellipse/parabola/hyperbola。

12.2 Statistics Exercises

重点题型:

- true/false 判断:
 - regularised estimate 通常 biased;
 - inverse variance estimate unbiased;
 - inverse variance weighting 是 BLUE;
 - regularised estimate 可以有更低 MSE。
- 概念解释:
 - BLUE minimises variance only among unbiased linear estimators;
 - minimum MSE may accept bias to reduce variance;
 - data mining 中的 underfitting / overfitting 是 bias-variance tradeoff 的预测版本。
- 计算:
 - ordinary LS estimate;
 - covariance matrix;
 - non-identically distributed noise 下的 BLUE。

12.3 Lecture 6–7 High-frequency LS Practice Set

Use this section actively: read the question, cover the solution, derive it yourself, then compare.

12.3.1 Problem 1: Build Φ and Derive Normal Equations

Question. Suppose the model is:

$$y_i \approx \theta_1 + \theta_2 x_i + \theta_3 x_i^2, \quad i = 1, \dots, N.$$

1. Write y , θ , and Φ .
2. Write the LS objective.
3. Derive the normal equations.
4. State the closed-form solution and the rank condition.

Solution.

Stack the observations:

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix}.$$

The design matrix is:

$$\Phi = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_N & x_N^2 \end{bmatrix}.$$

The LS problem is:

$$\min_{\theta} \|y - \Phi\theta\|_2^2.$$

Let:

$$J(\theta) = (y - \Phi\theta)^T(y - \Phi\theta).$$

Expand:

$$J(\theta) = y^T y - 2\theta^T \Phi^T y + \theta^T \Phi^T \Phi \theta.$$

Differentiate:

$$\nabla_{\theta} J = -2\Phi^T y + 2\Phi^T \Phi \theta.$$

Set to zero:

$$\Phi^T \Phi \theta = \Phi^T y.$$

If Φ has full column rank, then $\Phi^T \Phi$ is invertible and:

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y.$$

Exam comments:

- If $N < 3$, full column rank is impossible.
- If all x_i values do not vary enough, columns can become dependent or nearly dependent.
- In practice, use QR/SVD/backslash rather than explicitly inverting $\Phi^T \Phi$.

12.3.2 Problem 2: Projection Geometry Gives Normal Equations

Question. Explain geometrically why the LS residual is orthogonal to the columns of Φ , and derive the normal equations from that fact.

Solution.

The fitted vector is:

$$\hat{y} = \Phi \hat{\theta}.$$

All possible fitted vectors lie in the column space:

$$\text{col}(\Phi).$$

OLS chooses the point in $\text{col}(\Phi)$ closest to y . Therefore the residual:

$$r = y - \Phi \hat{\theta}$$

must be orthogonal to every direction in $\text{col}(\Phi)$.

The columns of Φ span this space, so:

$$\Phi^T r = 0.$$

Substitute $r = y - \Phi \hat{\theta}$:

$$\Phi^T (y - \Phi \hat{\theta}) = 0.$$

Expand:

$$\Phi^T y - \Phi^T \Phi \hat{\theta} = 0.$$

Therefore:

$$\Phi^T \Phi \hat{\theta} = \Phi^T y.$$

This is the same normal equation obtained by differentiating the cost.

Exam sentence:

Least squares projects y onto $\text{col}(\Phi)$; the residual is orthogonal to that subspace, giving $\Phi^T r = 0$.

12.3.3 Problem 3: Prove OLS Is Unbiased and Find Its Covariance

Question. Suppose:

$$y = \Phi\theta_0 + \epsilon, \quad E[\epsilon] = 0, \quad \text{Cov}(\epsilon) = \sigma^2 I,$$

and Φ has full column rank. Show that ordinary LS is unbiased and compute its covariance.

Solution.

OLS estimator:

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y.$$

Substitute the data-generating model:

$$\begin{aligned} \hat{\theta} &= (\Phi^T \Phi)^{-1} \Phi^T (\Phi\theta_0 + \epsilon) \\ &= \theta_0 + (\Phi^T \Phi)^{-1} \Phi^T \epsilon. \end{aligned}$$

Take expectation:

$$\begin{aligned} E[\hat{\theta}] &= \theta_0 + (\Phi^T \Phi)^{-1} \Phi^T E[\epsilon] \\ &= \theta_0. \end{aligned}$$

So OLS is unbiased.

For covariance, the error is:

$$\hat{\theta} - \theta_0 = (\Phi^T \Phi)^{-1} \Phi^T \epsilon.$$

Use:

$$\text{Cov}(A\epsilon) = A\text{Cov}(\epsilon)A^T.$$

Here:

$$A = (\Phi^T \Phi)^{-1} \Phi^T.$$

Therefore:

$$\begin{aligned} \text{Cov}(\hat{\theta}) &= (\Phi^T \Phi)^{-1} \Phi^T (\sigma^2 I) \Phi (\Phi^T \Phi)^{-1} \\ &= \sigma^2 (\Phi^T \Phi)^{-1}. \end{aligned}$$

Exam comments:

- zero-mean error gives unbiasedness;
- $\Phi^T \Phi$ controls estimator variance;
- weak or nearly dependent columns make covariance large.

12.3.4 Problem 4: Derive Inverse-variance Weighting

Question. Suppose $\hat{\theta}_i$ are independent unbiased estimators of θ with:

$$\text{Var}(\hat{\theta}_i) = \sigma_i^2.$$

Find weights w_i such that:

$$\hat{\theta}_w = \sum_i w_i \hat{\theta}_i$$

is unbiased and has minimum variance.

Solution.

Unbiasedness:

$$\begin{aligned} E[\hat{\theta}_w] &= \sum_i w_i E[\hat{\theta}_i] \\ &= \theta \sum_i w_i. \end{aligned}$$

Therefore:

$$\sum_i w_i = 1.$$

Variance:

$$\text{Var}(\hat{\theta}_w) = \sum_i w_i^2 \sigma_i^2.$$

Optimisation problem:

$$\min_w \sum_i w_i^2 \sigma_i^2 \quad \text{s.t.} \quad \sum_i w_i = 1.$$

Lagrangian:

$$L = \sum_i w_i^2 \sigma_i^2 + \lambda \left(\sum_i w_i - 1 \right).$$

First-order condition:

$$\frac{\partial L}{\partial w_i} = 2w_i \sigma_i^2 + \lambda = 0.$$

Hence:

$$w_i = -\frac{\lambda}{2\sigma_i^2}.$$

Let:

$$c = -\frac{\lambda}{2}.$$

Then:

$$w_i = \frac{c}{\sigma_i^2}.$$

Use the constraint:

$$\sum_i w_i = 1.$$

Substitute:

$$\sum_i \frac{c}{\sigma_i^2} = 1.$$

Factor out c :

$$c \sum_i \frac{1}{\sigma_i^2} = 1.$$

So:

$$c = \frac{1}{\sum_j 1/\sigma_j^2}.$$

Therefore:

$$w_i = \frac{1/\sigma_i^2}{\sum_j 1/\sigma_j^2}.$$

Interpretation:

small variance $\rightarrow$ large inverse variance $\rightarrow$ large weight
 large variance $\rightarrow$ small inverse variance $\rightarrow$ small weight

12.3.5 Problem 5: BLUE with Correlated Noise

This is a medium/high probability exam-style problem.

Question. Suppose:

$$y = \Phi\theta + \epsilon, \quad E[\epsilon] = 0, \quad \text{Cov}(\epsilon) = R,$$

where $R \succ 0$ is known and Φ has full column rank. Consider a linear estimator:

$$\hat{\theta} = Z^T y.$$

1. Find the condition on Z for $\hat{\theta}$ to be unbiased.
2. Compute $\text{Cov}(\hat{\theta})$.
3. State the BLUE.
4. Show that it reduces to ordinary LS when $R = \sigma^2 I$.
5. Explain why knowing R matters in practice.

Solution.

Start with:

$$\hat{\theta} = Z^T y.$$

Substitute the model:

$$\begin{aligned}\hat{\theta} &= Z^T(\Phi\theta + \epsilon) \\ &= Z^T\Phi\theta + Z^T\epsilon.\end{aligned}$$

Take expectation:

$$\begin{aligned}E[\hat{\theta}] &= E[Z^T\Phi\theta + Z^T\epsilon] \\ &= Z^T\Phi\theta + Z^TE[\epsilon] \\ &= Z^T\Phi\theta.\end{aligned}$$

For unbiasedness, we need:

$$E[\hat{\theta}] = \theta$$

for every possible θ . Therefore:

$$Z^T\Phi\theta = \theta \quad \text{for all } \theta.$$

So:

$$Z^T\Phi = I.$$

This is the unbiasedness constraint.

Now compute the covariance:

$$\hat{\theta} - \theta = Z^T\epsilon$$

when $Z^T\Phi = I$. Therefore:

$$\begin{aligned}\text{Cov}(\hat{\theta}) &= E[(\hat{\theta} - \theta)(\hat{\theta} - \theta)^T] \\ &= E[Z^T\epsilon\epsilon^T Z] \\ &= Z^TE[\epsilon\epsilon^T]Z \\ &= Z^TRZ.\end{aligned}$$

So among all linear unbiased estimators, the goal is:

$$\min_Z Z^TRZ \quad \text{subject to} \quad Z^T\Phi = I.$$

The solution is:

$$Z^T = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1}.$$

Therefore the BLUE is:

$$\hat{\theta}_{\text{BLUE}} = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} y.$$

Its covariance is:

$$\text{Cov}(\hat{\theta}_{\text{BLUE}}) = (\Phi^T R^{-1} \Phi)^{-1}.$$

Now check the white-noise special case. If:

$$R = \sigma^2 I,$$

then:

$$R^{-1} = \frac{1}{\sigma^2} I.$$

Substitute into BLUE:

$$\begin{aligned} \hat{\theta}_{\text{BLUE}} &= \left(\Phi^T \frac{1}{\sigma^2} I \Phi \right)^{-1} \Phi^T \frac{1}{\sigma^2} I y \\ &= \left(\frac{1}{\sigma^2} \Phi^T \Phi \right)^{-1} \frac{1}{\sigma^2} \Phi^T y \\ &= \sigma^2 (\Phi^T \Phi)^{-1} \frac{1}{\sigma^2} \Phi^T y \\ &= (\Phi^T \Phi)^{-1} \Phi^T y. \end{aligned}$$

So when the noise is white, BLUE reduces to ordinary LS.

Interpretation:

ordinary LS:

assumes $R = \sigma^2 I$

correlated-noise BLUE:

uses R^{-1} to account for variance and correlation structure

Practical issue: to compute the best linear unbiased estimator, you need to know or estimate R . In an exam, R may be given. In real data, estimating R can be difficult.

Common mistakes:

- writing ordinary LS when the question gives nontrivial R ;
- forgetting the unbiasedness constraint $Z^T \Phi = I$;
- saying correlated noise makes LS biased. Ordinary LS can still be unbiased, but it is generally not best;
- forgetting that R^{-1} disappears only when $R = \sigma^2 I$.

12.3.6 Problem 6: Explain Bias-variance Tradeoff and Regularisation

Question. Explain why an unbiased LS estimator is not necessarily the minimum-MSE estimator. Then explain how ridge regularisation changes bias and variance.

Solution.

The key identity is:

$$\text{MSE} = \text{Bias}^2 + \text{Variance}.$$

An unbiased estimator satisfies:

$$E[\hat{\theta}] = \theta_0,$$

so:

$$\text{Bias} = 0.$$

Then:

$$\text{MSE} = \text{Variance}.$$

But this only says that MSE equals variance **inside the unbiased case**. It does not prove that no biased estimator can have smaller total MSE.

Ridge solves:

$$\min_{\theta} \|y - \Phi\theta\|_2^2 + \eta\|\theta\|_2^2.$$

The solution is:

$$\hat{\theta}_{\eta} = (\Phi^T \Phi + \eta I)^{-1} \Phi^T y.$$

For $\eta > 0$, the estimate is shrunk toward zero. Usually:

```
eta increases
-> variance decreases
-> bias increases
```

This can improve MSE if the variance reduction is larger than the bias increase:

$$\Delta \text{Variance} > \Delta \text{Bias}^2.$$

Exam sentence:

```
BLUE minimises variance among unbiased linear estimators; ridge may be biased but can have lower MSE
```

Connection to validation:

```
training error usually decreases as model flexibility increases
validation error estimates future prediction error
choose eta by validation/CV, not by training residual alone
```

12.3.7 Problem 7: Nonlinear LS as Repeated Linear LS

Question. Suppose:

$$y_{\text{obs}} = H(\theta) + \epsilon.$$

Explain how Gauss-Newton turns nonlinear LS into repeated linear LS problems.

Solution.

The nonlinear least-squares objective is:

$$\min_{\theta} \frac{1}{2} \|y_{\text{obs}} - H(\theta)\|_2^2.$$

At current estimate θ_k , linearise H :

$$H(\theta_k + \delta\theta) \approx H(\theta_k) + J_k \delta\theta,$$

where:

$$J_k = \left. \frac{\partial H}{\partial \theta} \right|_{\theta_k}.$$

Define current residual:

$$r_k = y_{\text{obs}} - H(\theta_k).$$

Then:

$$y_{\text{obs}} - H(\theta_k + \delta\theta) \approx r_k - J_k \delta\theta.$$

So the local problem is:

$$\min_{\delta\theta} \|r_k - J_k \delta\theta\|_2^2.$$

This is an ordinary linear LS problem with:

```
output vector      = r_k
regressor matrix   = J_k
unknown parameter  = delta theta
```

The normal equations are:

$$J_k^T J_k \delta\theta = J_k^T r_k.$$

Solve for $\delta\theta$, then update:

$$\theta_{k+1} = \theta_k + \delta\theta.$$

Then re-linearise and repeat.

Exam sentence:

Gauss-Newton solves nonlinear least squares by repeatedly linearising the model and solving a local LS problem.

Common mistakes:

- treating one linearisation as the global nonlinear solution;
- forgetting that J_k changes after each update;
- confusing gradient descent with Gauss-Newton. Gauss-Newton solves a local LS problem, not just a fixed-size step along the negative gradient.

12.4 Convex Optimisation Exercises

重点题型:

- prove convexity:

- $C = \{x \mid Ax \leq b\}$;
- intersection of convex sets;
- norm cone $\{(r, x) \mid \|x\| \leq r\}$.
- formulate as LP:
 - $\min \|Ax - b\|_\infty$;
 - $\min \|Ax - b\|_1$;
 - use epigraph variables and linear inequalities.

Lower priority:

- S-procedure minimum-volume ellipsoid problem is beyond examination detail, but the idea that ellipsoid containment can become an SDP is useful.

13 Exam Templates and Common Mistakes

13.1 Template: Form a Least-squares Problem

1. Identify output vector y .
2. Choose parameter vector θ .
3. Build each row of Φ from the model and data.
4. Write residual $r = y - \Phi\theta$.
5. Minimise $\|r\|_2^2$.
6. If full column rank, use $(\Phi^T\Phi)^{-1}\Phi^Ty$.

Common mistakes:

- using $\Phi\Phi^T$ instead of $\Phi^T\Phi$;
- forgetting the dimensions of θ ;
- treating noisy x and noisy y as ordinary LS without comment.

13.2 Template: Show OLS Is Unbiased

Use this when the question asks whether ordinary least squares is unbiased.

Assume:

$$y = \Phi\theta_0 + \epsilon, \quad E[\epsilon] = 0, \quad \Phi^T\Phi \text{ invertible.}$$

Then:

$$\begin{aligned}
\hat{\theta} &= (\Phi^T \Phi)^{-1} \Phi^T y \\
&= (\Phi^T \Phi)^{-1} \Phi^T (\Phi \theta_0 + \epsilon) \\
&= \theta_0 + (\Phi^T \Phi)^{-1} \Phi^T \epsilon.
\end{aligned}$$

Therefore:

$$\begin{aligned}
E[\hat{\theta}] &= \theta_0 + (\Phi^T \Phi)^{-1} \Phi^T E[\epsilon] \\
&= \theta_0.
\end{aligned}$$

So:

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta_0 = 0.$$

Exam sentence:

Under fixed Φ , full column rank, and zero-mean y -error, OLS is unbiased.

13.3 Template: Answer a BLUE Question

1. Start from $\hat{\theta} = Z^T y$.
2. Use $y = \Phi \theta + \epsilon$.
3. For unbiasedness:

$$E[\hat{\theta}] = Z^T \Phi \theta = \theta \Rightarrow Z^T \Phi = I$$

4. Covariance:

$$\text{Cov}(\hat{\theta}) = Z^T R Z$$

5. State the BLUE:

$$\hat{\theta} = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} y$$

Common mistakes:

- assuming $R = I$ when the question gives correlated noise;
- saying BLUE minimises MSE rather than variance among unbiased linear estimators.

13.4 Template: Derive Inverse-variance Weights

Use this for combining independent unbiased estimates.

Given:

$$E[\hat{\theta}_i] = \theta, \quad \text{Var}(\hat{\theta}_i) = \sigma_i^2, \quad \hat{\theta}_w = \sum_i w_i \hat{\theta}_i.$$

Unbiasedness:

$$E[\hat{\theta}_w] = \theta \sum_i w_i \Rightarrow \sum_i w_i = 1.$$

Variance:

$$\text{Var}(\hat{\theta}_w) = \sum_i w_i^2 \sigma_i^2.$$

Optimisation:

$$\min_w \sum_i w_i^2 \sigma_i^2 \quad \text{s.t.} \quad \sum_i w_i = 1.$$

Lagrangian:

$$L = \sum_i w_i^2 \sigma_i^2 + \lambda \left(\sum_i w_i - 1 \right).$$

First-order condition:

$$2w_i \sigma_i^2 + \lambda = 0 \Rightarrow w_i = \frac{c}{\sigma_i^2}.$$

Use $\sum_i w_i = 1$:

$$c \sum_i \frac{1}{\sigma_i^2} = 1 \Rightarrow c = \frac{1}{\sum_j 1/\sigma_j^2}.$$

Therefore:

$$w_i = \frac{1/\sigma_i^2}{\sum_j 1/\sigma_j^2}.$$

Exam sentence:

The minimum-variance unbiased linear combination weights each estimate in proportion to inverse variance.

13.5 Template: Explain Regularisation

Use this structure:

Regularisation adds a penalty term to the fitting objective.

It shrinks the estimate, which increases bias but decreases variance.

This can reduce MSE and improve prediction, especially when the problem is ill-conditioned.

The hyperparameter eta is usually selected by validation or cross-validation.

13.6 Template: Prove Convexity of a Set

1. Take arbitrary x_1, x_2 in the set.
2. Let $x_\gamma = \gamma x_1 + (1 - \gamma)x_2$, with $\gamma \in [0, 1]$.
3. Show x_γ also satisfies the set condition.
4. Conclude the set is convex.

For $C = \{x \mid Ax \leq b\}$:

$$A(\gamma x_1 + (1 - \gamma)x_2) = \gamma Ax_1 + (1 - \gamma)Ax_2 \leq \gamma b + (1 - \gamma)b = b$$

13.7 Template: Formulate MPC

1. State current state x_0 .
2. Define decision variables:
 - $u_0, \dots, u_{M-1}$;
 - $x_1, \dots, x_M$.
3. Write dynamics constraints.
4. Add hard constraints.
5. Add soft constraints as penalties if needed.
6. Add terminal cost or terminal constraint.
7. Solve, apply only u_0 , then replan.

Common mistakes:

- forgetting that only the first input is applied;
- treating forecasts as feedback;
- omitting state estimation even though state is usually estimated, not directly measured;
- writing terminal constraints without explaining their role.

14 Appendix: Practical EDA for Candidate Φ

这部分不是 Roy Smith least-squares 章节的考试重点，而是帮助把 DATA423 的 feature workflow 和 Φ 的矩阵视角连接起来。

实践中，在正式拟合之前，我们通常会对 candidate Φ 做 EDA。核心问题是：

`Do these candidate columns have useful, independent variation for explaining y?`

更具体地说：

- 每一列自己是否有足够变化；
- columns 之间是否高度相关；
- columns 是否和 y 有合理关系；
- Φ 是否 full rank；
- Φ 是否 ill-conditioned；
- 是否存在 outliers 或 high leverage points；
- 是否有 domain reason 支持这些 columns。

14.1 R: From Formula to Φ

在 R 里，`lm()` 公式背后会自动构造 design matrix，也就是这里的 Φ 。

例如：

```
model <- lm(y ~ x1 + x2 + x1:x2, data = df)
X <- model.matrix(model)
```

这里：

$$X = \Phi$$

如果公式是：

```
y ~ x1 + x2 + x1:x2
```

那么 Φ 的 columns 大致是：

$$1, \quad x_1, \quad x_2, \quad x_1x_2$$

如果写：

```
y ~ poly(x, 3)
```

则 R 会构造三阶 polynomial 相关的 columns。实际生成的列是否是原始 powers 或 orthogonal polynomial, 取决于 `poly()` 的设置。

因此, 一个很实用的习惯是:

```
X <- model.matrix(model)
head(X)
dim(X)
```

先看清楚模型真正送进 LS 的 Φ 长什么样。

14.2 Check 1: Single-Column Variation

第一步看每个 feature 自己有没有变化。几乎常数的 column 不会提供多少信息, 还可能导致数值问题。

```
summary(df)
sapply(df[predictors], sd, na.rm = TRUE)
```

如果使用 `caret`:

```
caret::nearZeroVar(df[predictors])
```

矩阵语言:

```
near-zero variance column
-> almost no direction in data
-> weak information for estimating its coefficient
```

注意: variance 大不等于一定 useful。它还需要和 y 有关系, 并且不能只是其他 columns 的重复。

14.3 Check 2: Pairwise Correlation Between Features

相关矩阵检查 columns 是否两两接近线性相关:

```
cor(df[predictors], use = "complete.obs")
```

可视化:

```
pairs(df[predictors])
```

如果:

$$\text{corr}(x_1, x_2) \approx 1$$

那么 Φ 的两列方向几乎一样, 容易造成 multicollinearity。

矩阵语言:

```
highly correlated columns
-> Phi columns nearly linearly dependent
-> larger condition number
-> unstable coefficient estimates
```

但 pairwise correlation 不是完整诊断。两两相关不高，也可能多个 columns 合在一起造成 dependence。

14.4 Check 3: Relationship Between Each Feature and y

单独看 feature 和 output 的关系：

```
library(ggplot2)

ggplot(df, aes(x1, y)) +
  geom_point() +
  geom_smooth()
```

这类图主要看：

- 是否有大致线性关系；
- 是否有 nonlinear pattern；
- 是否需要 transformation；
- 是否存在 outliers；
- 是否不同区间有不同趋势；
- 是否应该加入 interaction。

例如如果 x_1 和 y 的关系随 x_2 改变，就可能考虑：

$$x_1 x_2$$

作为 interaction column。

14.5 Check 4: Multicollinearity Beyond Pairwise Correlation

VIF 检查一个 predictor 能否被其他 predictors 解释。

```
model <- lm(y ~ x1 + x2 + x3, data = df)
car::vif(model)
```

直觉：

```
high VIF for x_j
-> x_j is predictable from other features
-> coefficient for x_j is unstable
```

这比 pairwise correlation 更强，因为它检查的是 one column vs all other columns。

14.6 Check 5: Rank and Condition Number of Φ

这是最直接对应 Roy Smith 这里的检查。

```
model <- lm(y ~ x1 + x2 + x1:x2, data = df)
X <- model.matrix(model)

qr(X)$rank
ncol(X)
kappa(X)
```

解释：

```
qr(X)$rank == ncol(X)
-> full column rank

qr(X)$rank < ncol(X)
-> lose rank
-> some coefficients not identifiable

kappa(X) large
-> ill-conditioned
-> coefficients sensitive to noise
```

如果想看 singular values：

```
svd(X)$d
```

如果最小 singular value 很接近 0：

$$\sigma_{\min}(\Phi) \approx 0$$

说明某些 feature direction 几乎没有被数据激发出来。

14.7 Check 6: Residual Diagnostics After Fitting

前面的 EDA 是拟合前检查 Φ 。拟合后还要看 residuals：

```
par(mfrow = c(2, 2))
plot(model)
```

对应检查：

- Residuals vs Fitted: 是否有系统性模式;
- Q-Q Residuals: residual 是否近似 normal;
- Scale-Location: 是否 heteroscedastic;
- Residuals vs Leverage: 是否有 high leverage / influential points。

这一步回答的是:

`Given this Phi, does the fitted residual look like reasonable noise?`

如果 residual 有明显结构, 可能说明 Φ 的 columns 还没有表达出重要关系, 需要重新做 feature engineering 或 extraction。

14.8 Check 7: Anscombe Warning and High-Dimensional Φ

Roy 用 Anscombe dataset 提醒我们: 仅看 summary statistics 会误导。四组数据可以有相同的:

- mean of x ;
- mean of y ;
- variance of x ;
- variance of y ;
- fitted line slope and intercept;
- correlation-like summary;

但图像结构完全不同。只有一组适合线性拟合; 其他可能是 nonlinear relation、outlier-driven relation, 或者根本没有关系。

这对 Φ 的教训是:

summary statistics are not enough; the geometry of the data matters.

这也连接到主章节里的 data-driven optimisation warning: 如果 optimisation 的 objective、constraint 或 parameters 来自 fitted model, 那么没有检查 data geometry 就直接优化, 会把建模错误放大成决策错误。

当 $d \leq 2$ 或 $d \leq 3$ 时, 我们可以比较直接地画出 data cloud 或 column space 的几何图像。但当 Φ 有很多 columns 时, 完整可视化不现实。这时不要放弃可视化, 而是改成分层、切片、投影和诊断图。

14.8.1 What To Do When $d > 3$

高维时, 实践策略不是“画一张完整的高维图”, 而是:

`visualise useful 2D/3D summaries of the high-dimensional structure`

推荐操作如下。

第一, 画 pairwise feature plots。目标是发现 obvious nonlinear patterns、clusters、outliers 和 collinearity。

```
pairs(df[predictors])
```

如果 predictors 很多，不要画全部。先画：

- domain-important variables;
- 与 y correlation 较高的 variables;
- VIF 高的 variables;
- suspected interaction variables。

第二，画每个重要 feature 对 y 的关系：

```
ggplot(df, aes(x1, y)) +  
  geom_point() +  
  geom_smooth()
```

这不是为了证明模型正确，而是为了发现：

- line 是否合理；
- 是否更像 polynomial；
- 是否被 outlier 驱动；
- 是否存在 threshold / saturation；
- 是否需要 interaction。

第三，画 residual vs fitted：

```
plot(model, which = 1)
```

如果 residual vs fitted 有曲线、漏斗形或分层，说明 Φ 可能没有表达出重要结构。

第四，画 residual vs important predictors：

```
df$resid <- residuals(model)  
  
ggplot(df, aes(x1, resid)) +  
  geom_point() +  
  geom_smooth()
```

如果 residual 对某个 predictor 仍有模式，说明这个 predictor 的关系没有被当前 Φ 正确表达。可能需要：

- nonlinear term;
- transformation;
- interaction;
- 分组模型；
- 不同 model class。

第五，用 partial residual / component-plus-residual plots 看某个 predictor 在控制其他 predictors 后的形状。

```
car::crPlots(model)
```

这比单独画 x_j vs y 更接近多元回归语境，因为它部分控制了其他 columns 的影响。

第六，检查 leverage 和 influential points:

```
plot(model, which = 5)
cooks.distance(model)
hatvalues(model)
```

Anscombe 的一个重要教训就是：一两个点可能制造出看似合理的 slope。高维时更要检查 high leverage，因为某些点在单变量图里不显眼，但在 Φ 的 column space 中非常极端。

第七，用 low-dimensional projection 看整体结构。比如 PCA:

```
X <- model.matrix(model)[, -1]
X_scaled <- scale(X)
pca <- prcomp(X_scaled)

plot(pca$x[, 1], pca$x[, 2])
```

如果想看 y 或 residual 在 projection 上的结构:

```
plot(pca$x[, 1], pca$x[, 2], col = cut(df$y, 4))
```

或:

```
plot(pca$x[, 1], pca$x[, 2], col = cut(residuals(model), 4))
```

这回答的是:

```
In the main variation directions of Phi, do y or residuals show structure?
```

第八，做 sample slicing。高维关系常常只在某些区间里显现。可以按某个变量分组，再画局部关系:

```
ggplot(df, aes(x1, y)) +
  geom_point() +
  geom_smooth() +
  facet_wrap(~ group_var)
```

如果不同 slice 的 slope 不同，就可能需要 interaction:

$$x_1 x_2$$

第九，把 visual checks 和 validation 结合。高维时不可能靠眼睛确认全部结构，所以最后要看:

```
resampling / cross-validation / test performance
```

视觉检查帮助我们发现 model misspecification; validation 帮助我们判断新的 Φ 是否真的提升泛化。

14.8.2 High-Dimensional EDA Checklist

当 Φ 很宽时，可以按这个顺序做：

1. Check column variance and missingness.
2. Check pairwise correlations for important predictors.
3. Check VIF / rank / condition number.
4. Plot y vs key predictors.
5. Fit baseline model.
6. Plot residuals vs fitted.
7. Plot residuals vs key predictors.
8. Check leverage and Cook's distance.
9. Use PCA/low-dimensional projection of Φ .
10. Validate candidate Φ designs by cross-validation.

核心态度是：

Do not trust statistics alone; use plots to find structure, and use validation to test whether the structure helps prediction.

14.9 Practical Workflow

一个实际但不复杂的 workflow：

1. Start from domain variables.
2. Build candidate features: transformations, interactions, basis functions.
3. Inspect each column: variance, missingness, units, scale.
4. Inspect relationships: feature-feature correlation and feature- y plots.
5. Build Φ via `model.matrix()`.
6. Check rank and condition number.
7. Fit model.
8. Check residual diagnostics.
9. Use validation/cross-validation for model selection.
10. Revise Φ if needed.

这个流程的重点不是“机械删除所有高相关变量”，而是理解：

useful information for estimating θ lives in independent, relevant variation of the columns of Φ .

因此，EDA 不是替代 LS，而是在问 LS 所依赖的 design matrix 是否真的含有足够信息。

15 Appendix: Φ as Hidden Structure and Dynamics

这部分把前面关于 Φ 的直觉再提升一层： Φ 不只是一个 data table，也不只是 R 里 `model.matrix()` 生成的矩阵。它是模型把世界压缩成可计算结构的方式。

核心句子：

choosing Φ means choosing what kinds of variation the model is allowed to explain.

也可以说：

every column of Φ is an implicit hypothesis about the mechanism behind y .

在 LS 里：

$$y \approx \Phi\theta$$

这句话不只是代数式。它隐含地说：

y mainly varies along the directions represented by the columns of Phi.

因此， Φ 的列既是数学 basis，也是 assumptions about structure, dynamics, physics, behaviour, or data generation。

15.1 Common Φ Constructions and Their Implicit Assumptions

Φ construction	Example columns	Implicit assumption
Linear features	$1, x_1, x_2$	y 对输入的响应近似线性
Polynomial basis	$1, x, x^2, x^3$	关系是平滑曲线，可由局部弯曲近似
Chebyshev basis	$T_0(x), T_1(x), T_2(x)$	关系在区间内平滑，并希望数值更稳定
Interaction terms	x_1x_2	一个变量的影响取决于另一个变量
Log features	$\log x$	边际效应递减，或关系更像比例变化
Sin/cos seasonal terms	$\sin(2\pi t/T), \cos(2\pi t/T)$	数据有周期性，例如日、周、年
Lag features	$y_{t-1}, y_{t-2}, u_{t-1}$	当前状态受过去状态/输入影响
Conic section basis	$x^2, xy, y^2, x, y, 1$	轨迹近似服从二体中心力运动
PTDF / sensitivity matrix	PTDF p	潮流可由 DC power flow 线性近似
Jacobian / linearisation	$H_\theta(\theta_i)$	非线性系统在局部可线性化
PCA components	$z_1, z_2, \dots$	主要信息在少数 latent directions 中
One-hot categories	indicator columns	不同类别有不同 baseline effect

Φ construction	Example columns	Implicit assumption
Splines	piecewise basis	关系平滑，但不同区间曲率不同

这张表的重点不是背例子，而是看出模式：

```
choose columns
-> choose allowed variation directions
-> choose implicit model structure
```

15.2 Orbit Fitting: Polynomial vs Conic Section

Roy 讲 conic section 时，重点不是“圆锥曲线比多项式更高级”，而是：

conic section encodes the physics of ideal two-body motion.

如果用 polynomial：

$$y \approx a_0 + a_1x + a_2x^2 + a_3x^3$$

隐含假设是：

the trajectory is a smooth graph $y=f(x)$ that can be locally bent by polynomial terms.

如果用 conic section：

$$Ax^2 + Bxy + Cy^2 + Dx + Ey + F = 0$$

隐含假设变成：

the trajectory is close to the solution of a two-body central-force problem.

其物理线索是：

```
inverse-square central force
+ conservation of energy
+ conservation of angular momentum
-> conic sections
```

所以 conic basis：

$$x^2, xy, y^2, x, y, 1$$

不是任意的 feature engineering。它把二体轨道的几何结构写进了 Φ 。

这就是为什么短时间 polynomial 也许能 fit 一段轨迹，但如果要 extrapolate orbit 或解释 physical orbital parameters, conic section 更自然。

15.3 Industrial Examples

下面这些例子帮助建立直觉：工业中的 Φ 往往来自物理模型、工程近似、过程知识或行为假设。

15.3.1 Power Systems: DC Power Flow / OPF

可能有：

$$f \approx \text{PTDF } p$$

这里 Φ 来自 PTDF 或 sensitivity matrix。

隐含假设：

```
voltage magnitudes near 1 p.u.
angle differences small
reactive power ignored
network topology fixed
line flows approximately linear in injections
```

所以 Φ 编码的是 DC power flow 近似，而不是任意矩阵。

15.3.2 Refinery / Chemical Process Scheduling

可能有：

$$\text{product output} \approx \Phi \cdot \text{feedstock mix}$$

Φ 的列可能是不同 crude oil 的 yield profile，例如某种原油能炼出多少 petrol、diesel、jet fuel。

隐含假设：

```
yield coefficients approximately stable
blending is roughly linear
process units operate in known regimes
capacity constraints known
```

这类 Φ 来自过程工程知识和历史 plant data。

15.3.3 Manufacturing: Production Time / Throughput Model

例如:

$$\text{production time} \approx \theta_0 + \theta_1(\text{batch size}) + \theta_2(\text{setup}) + \theta_3(\text{shift})$$

隐含假设:

```
batch size affects time predictably
setup cost adds fixed overhead
shift/operator effects can be separated
relationship stable across observations
```

如果加入 interaction:

$$\text{batch size} \times \text{shift}$$

则是在假设 batch-size effect depends on shift/operator context。

15.3.4 Structural Engineering: Modal Basis

在结构动力学或有限元降阶里, 可能写:

$$u \approx \Phi q$$

其中 Φ 的列是 mode shapes, q 是 modal coordinates。

隐含假设:

```
deformation can be represented by selected modes
high-frequency modes are negligible
linear elasticity approximately holds
```

这里 Φ 的列是结构系统“自然振动方式”的方向。

15.3.5 Control System Identification

线性 state-space identification 常写:

$$x_{t+1} \approx Ax_t + Bu_t$$

写成 LS 时, Φ 包含:

$$[x_t, u_t]$$

隐含假设:

```
next state depends linearly on current state and input
dynamics are time-invariant over the dataset
unmodelled effects are noise
```

如果系统是 nonlinear, 则可能用 Jacobian linearisation 得到 local Φ 。

15.3.6 Predictive Maintenance

Φ 可能包含:

```
temperature
vibration RMS
load
operating hours
recent trend
```

隐含假设:

```
failure risk is related to measurable degradation signals
recent history contains predictive information
sensor features summarize machine condition
```

如果 residual 仍有结构, 可能说明某些 degradation mechanism 没有被当前 Φ 捕捉。

15.3.7 Traffic and Network Flow

Φ 可能包含:

```
previous traffic volume
speed
time of day
day of week
weather
event indicator
```

隐含假设:

```
traffic has temporal dependence
daily/weekly cycles matter
weather/events perturb baseline flow
```

这里 lag features 和 seasonal features 都是在把动态结构写入 Φ 。

15.3.8 Finance / Risk Factor Models

Factor model:

$$r_i \approx \beta_{i1}f_1 + \beta_{i2}f_2 + \cdots + \epsilon_i$$

Φ 是 market factors。

隐含假设:

```
asset returns are driven by common latent/economic factors
idiosyncratic noise is residual
factor exposure is stable over fitting window
```

15.3.9 Healthcare / Biostatistics

Φ 可能包含:

```
age
BMI
blood pressure
biomarkers
treatment indicator
interaction terms
```

隐含假设:

```
outcome varies systematically with physiological covariates
treatment effect can be separated from baseline risk
interactions may represent subgroup effects
```

15.3.10 Demand Forecasting / Supply Chain

Φ 可能包含:

```
price
promotion indicator
holiday
season
lagged demand
competitor price
```

隐含假设:

```
demand responds to price and promotion
seasonality matters
past demand carries information about future demand
```

15.4 The Main Intuition

把所有例子压缩成一句:

Φ is the model's account of why y varies.

所以构造 Φ 时, 不只是在做数据预处理, 而是在回答:

```
What mechanisms, dynamics, cycles, interactions, or physical laws
do I believe generate the observed variation in y?
```

如果 Φ 选得好, least squares 是在正确的 structural directions 上投影。如果 Φ 选得差, least squares 仍然会给出最小 residual, 但可能是在错误的假设空间里找到的最优解。

16 Appendix: Math Background - SVD and Pseudo-inverse

这部分是 rank、condition number、pseudo-inverse 和 regularisation 的共同数学背景。考试不一定要求完整证明 SVD, 但理解它会让 Roy 提到的 singular、rank deficient、pseudo-inverse 更自然。

16.1 What SVD Says

Singular value decomposition, SVD, 写成:

$$\Phi = U\Sigma V^T$$

它的几何直觉是:

```
V^T      : rotate / re-express input directions
Sigma    : stretch or compress each special direction
U        : rotate / re-express output directions
```

所以任何矩阵 Φ 的作用都可以理解成:

```
input vector
-> rotate to special coordinates
-> scale each direction by singular values
-> rotate into output space
```

其中最重要的是 Σ 。它通常形如：

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & \cdots \\ 0 & \sigma_2 & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

对角线上的：

$$\sigma_1, \sigma_2, \dots$$

叫 singular values。

16.2 Geometric Picture: Circle to Ellipse

在二维直觉里，可以想象一个单位圆。矩阵 Φ 作用在这个圆上后，通常会变成椭圆：

circle -> ellipse

SVD 告诉我们：

- V^T 找到输入空间里哪些方向会变成椭圆主轴；
- Σ 给出这些主轴被拉伸或压缩的长度；
- U 告诉我们这个椭圆在输出空间里朝哪个方向。

因此 singular values 可以理解成椭圆半轴长度。

如果：

$$\sigma_i \text{ large}$$

说明这个方向被数据/矩阵强烈看见。

如果：

$$\sigma_i \text{ small}$$

说明这个方向被压得很扁，估计会对噪声敏感。

如果：

$$\sigma_i = 0$$

说明这个方向被完全压没了，信息丢失。

16.3 Singular and Rank Deficient

一个 square matrix 如果 singular，意思是它不可逆：

$$A^{-1} \text{ does not exist}$$

几何上，它把至少一个非零方向压成了零：

$$Ax = 0, \quad x \neq 0$$

所以不同输入可能给出同一个输出，无法反向唯一恢复。

对 LS 来说，如果 Φ not full column rank，则存在：

$$v \neq 0$$

使得：

$$\Phi v = 0$$

这意味着：

$$\Phi(\theta + \alpha v) = \Phi\theta$$

任意 α 都给出同样 prediction，因此参数不唯一。这就是 rank deficient 的本质。

用 SVD 看，rank 就是非零 singular values 的数量：

$$\text{rank}(\Phi) = \#\{i : \sigma_i > 0\}$$

16.4 Condition Number Through SVD

Condition number 可以写成：

$$\kappa(\Phi) = \frac{\sigma_{\max}}{\sigma_{\min}}$$

如果 $\sigma_{\min}$ 很小，说明存在某个方向几乎看不见。此时：

```
small data noise
-> large coefficient uncertainty
```

Normal equations 会形成:

$$\Phi^T \Phi$$

它的 singular/eigen values 对应大致会平方, 所以:

$$\kappa(\Phi^T \Phi) = \kappa(\Phi)^2$$

这就是为什么直接用 normal-equation inverse 在数值上可能更糟。

16.5 Pseudo-inverse from SVD

普通 inverse 的思想是: 每个方向都反向缩放。

如果某方向被乘以:

$$\sigma_i$$

反解时要乘以:

$$\frac{1}{\sigma_i}$$

但如果:

$$\sigma_i = 0$$

就不能取倒数。Pseudo-inverse 的做法是:

$$\sigma_i^+ = \begin{cases} 1/\sigma_i, & \sigma_i \neq 0 \\ 0, & \sigma_i = 0 \end{cases}$$

因此如果:

$$\Phi = U \Sigma V^T$$

则:

$$\Phi^+ = V\Sigma^+U^T$$

直觉:

directions with information: invert the scaling
directions with zero information: do not guess

所以 pseudo-inverse 承认有些方向数据没有告诉我们, 不强行恢复那些方向。

16.6 Meaning in Least Squares

在:

$$y \approx \Phi\theta$$

中, SVD 告诉我们:

which parameter directions are strongly visible in the data
which directions are weakly visible
which directions are invisible

如果 full column rank 且 well-conditioned, ordinary LS 很稳定。

如果 rank deficient, 有无限多组 θ 可能给出同样 prediction。Pseudo-inverse 选择其中 norm 最小的:

$$\hat{\theta} = \arg \min_{\Phi\theta=y} \|\theta\|_2$$

如果没有 exact solution, pseudo-inverse 给 least-squares best fit:

$$\hat{\theta} = \arg \min_{\theta} \|\Phi\theta - y\|_2$$

更完整地说, pseudo-inverse 在多解时选 minimum-norm solution。

16.7 Why Small Singular Values Are Dangerous

如果:

$$\sigma_i = 0.001$$

pseudo-inverse 会用:

$$\frac{1}{\sigma_i} = 1000$$

这会把该方向上的噪声也放大 1000 倍。

所以 small singular values 虽然不是严格 zero，但仍然危险。它们对应：

`nearly unidentifiable directions`

这就是 regularisation 和 truncated SVD 的动机：

- pseudo-inverse: invert all nonzero directions;
- truncated SVD: ignore very small directions;
- ridge regularisation: shrink unstable directions instead of fully inverting them.

16.8 One-Line Summary

SVD 是看 Φ 的“方向显微镜”：

```
large singular value -> data strongly identifies that direction
small singular value -> direction is weak and noise-sensitive
zero singular value  -> direction is invisible / rank deficient
```

Pseudo-inverse 是基于这个显微镜做的 generalized inverse：

```
invert what can be inverted,
ignore what has been completely lost,
choose the minimum-norm solution when many solutions exist.
```

17 Appendix: Projection Geometry and Instrumental Variables

这部分补充 Roy 在 Lecture 6 里用几何解释导出 normal equations，并顺势引出 instrumental variable methods 的思路。它不是新的 LS 公式，而是同一个问题的另一种视角。

17.1 Projection View of Least Squares

Least-squares problem 是：

$$\min_{\theta} \|y - \Phi\theta\|_2^2$$

其中：

$$y \in \mathbb{R}^N, \quad \Phi \in \mathbb{R}^{N \times d}, \quad \theta \in \mathbb{R}^d$$

$\Phi\theta$ 是 Φ 的 columns 的 linear combination。因此所有可能的 fitted values:

$$\hat{y} = \Phi\theta$$

都落在 Φ 的 column space 里:

$$\text{col}(\Phi)$$

几何上, OLS 做的是:

把 y 投影到 $\text{col}(\Phi)$ 上, 找到离 y 最近的点 $\hat{y} = \Phi\theta^*$ 。

残差是:

$$\epsilon = y - \Phi\theta^*$$

投影 theorem 告诉我们, 最近点处的 residual 必须垂直于这个 subspace:

$$\epsilon \perp \text{col}(\Phi)$$

也就是说 residual 不仅垂直于 $\Phi\theta^*$, 更强地说, 它垂直于 Φ 的每一列:

$$\phi_i^T \epsilon = 0, \quad i = 1, \dots, d$$

把这些条件叠成矩阵形式:

$$\Phi^T \epsilon = 0$$

这就是 normal equations 的几何来源。

17.2 Inner Product Notation

Roy 板书里写:

$$\langle \Phi\theta^*, \epsilon \rangle = 0$$

这里的 inner product 对实向量就是:

$$\langle a, b \rangle = a^T b$$

所以：

$$\langle \Phi\theta^*, \epsilon \rangle = (\Phi\theta^*)^T \epsilon$$

而 residual 是：

$$\epsilon = y - \Phi\theta^*$$

代入：

$$\langle \Phi\theta^*, y - \Phi\theta^* \rangle = 0$$

利用 inner product 的线性：

$$\langle a, b - c \rangle = \langle a, b \rangle - \langle a, c \rangle$$

得到：

$$\langle \Phi\theta^*, y \rangle - \langle \Phi\theta^*, \Phi\theta^* \rangle = 0$$

这对应你截图里的展开：

$$\langle \Phi\theta^*, y \rangle - \langle \Phi\theta^*, \Phi\theta^* \rangle = 0$$

17.3 Expanding the Inner Products Step by Step

第一项：

$$\langle \Phi\theta^*, y \rangle = (\Phi\theta^*)^T y$$

用转置规则：

$$(AB)^T = B^T A^T$$

所以：

$$(\Phi\theta^*)^T = (\theta^*)^T \Phi^T$$

因此：

$$\langle \Phi\theta^*, y \rangle = (\theta^*)^T \Phi^T y$$

第二项：

$$\langle \Phi\theta^*, \Phi\theta^* \rangle = (\Phi\theta^*)^T (\Phi\theta^*)$$

继续用同样的转置规则：

$$(\Phi\theta^*)^T (\Phi\theta^*) = (\theta^*)^T \Phi^T \Phi \theta^*$$

所以：

$$(\theta^*)^T \Phi^T y - (\theta^*)^T \Phi^T \Phi \theta^* = 0$$

提取共同的 $(\theta^*)^T$ ：

$$(\theta^*)^T (\Phi^T y - \Phi^T \Phi \theta^*) = 0$$

为了让这个 orthogonality condition 对 optimal projection 成立，括号中的 normal-equation residual 应该为 0：

$$\Phi^T y - \Phi^T \Phi \theta^* = 0$$

所以：

$$\Phi^T \Phi \theta^* = \Phi^T y$$

这就是 normal equations。

更直接、更标准的写法是从“residual 垂直于整个 column space”出发：

$$\Phi^T \epsilon = 0$$

代入 $\epsilon = y - \Phi\theta^*$ ：

$$\Phi^T(y - \Phi\theta^*) = 0$$

展开：

$$\Phi^T y - \Phi^T \Phi \theta^* = 0$$

所以：

$$\Phi^T \Phi \theta^* = \Phi^T y$$

这个版本更严谨，因为它直接表达了 residual 对 Φ 的每一列都正交，而不仅仅是对某一个 fitted vector $\Phi\theta^*$ 正交。

17.4 What This Has to Do with Instrumental Variables

OLS 的核心 moment condition 是：

$$\Phi^T \epsilon = 0$$

换句话说：

residual should be orthogonal to the regressors.

在 sample form 里，如果 Φ 的第 i 列是 regressor ϕ_i ，那么：

$$\sum_{j=1}^N \phi_{ji} \epsilon_j = 0$$

这表示 regressor 和 residual 没有剩余相关性。

但如果 regressors 和 true error 相关，例如：

$$\text{Cov}(\Phi, \epsilon) \neq 0$$

那么 OLS 的正交条件不再可信。此时强行要求：

$$\Phi^T \epsilon = 0$$

会让 estimator 吸收错误的相关性，导致 biased 或 inconsistent estimates。

Instrumental variables 的出发点就是换一个正交对象。我们找一个工具变量矩阵：

$$Z$$

它满足两个直觉条件：

1. Z 和 problematic regressors Φ 有关系；
2. Z 和 structural error ϵ 没关系。

对应写成：

$$\text{Cov}(Z, \Phi) \neq 0$$

和：

$$\text{Cov}(Z, \epsilon) = 0$$

于是 IV 不再要求 residual 对 Φ 正交，而是要求 residual 对 Z 正交：

$$Z^T \epsilon = 0$$

代入：

$$\epsilon = y - \Phi\theta$$

得到：

$$Z^T(y - \Phi\theta) = 0$$

展开：

$$Z^T y - Z^T \Phi \theta = 0$$

所以：

$$Z^T \Phi \theta = Z^T y$$

如果 $Z^T \Phi$ 可逆，则：

$$\hat{\theta}_{IV} = (Z^T \Phi)^{-1} Z^T y$$

这就是 Roy 说 instrumental variable methods 可以从 orthogonality point of view 出发的意思。

17.5 OLS vs IV as Orthogonality Conditions

可以把它们放在同一个框架里：

Method	Orthogonality condition	Meaning
OLS	$\Phi^T \epsilon = 0$	residual orthogonal to regressors
IV	$Z^T \epsilon = 0$	residual orthogonal to instruments

OLS 的几何图像是：

```
project y onto column space of Phi
residual perpendicular to col(Phi)
```

IV 的直觉是：

```
Phi may be contaminated
so use Z as clean directions
require residual to be orthogonal to Z instead
```

所以 Roy 这里的重点不是让你多背一个算法，而是让你看到：

least squares, normal equations, and instrumental variables all come from choosing which directions the residual must be orthogonal to.

18 Self Check

You should be able to answer these without notes:

1. What are the normal equations and where do they come from?
2. Why is the LS residual orthogonal to the column space of Φ ?
3. What is the difference between ordinary LS, weighted LS, and BLUE?
4. Why does minimum variance among unbiased estimators not imply minimum MSE?
5. What is the difference between algebraic consistency and statistical consistency?
6. How does regularisation change bias and variance?
7. What is a convex set?
8. Why are affine equality constraints allowed in convex optimisation?
9. What is the difference between LP, QP, SOCP, QCQP, and SDP?

10. What is an LMI?
11. What does the Schur complement help with?
12. How do you write an MPC optimisation problem?
13. Why does MPC apply only the first input?
14. What is explicit MPC, and why does it not scale well?

19 Minimum Memory List

- LS problem:

$$\min_{\theta} \|y - \Phi\theta\|_2^2$$

- Normal equations:

$$\Phi^T \Phi \theta = \Phi^T y$$

- Ordinary LS:

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T y$$

- OLS unbiased condition:

$$y = \Phi\theta_0 + \epsilon, \quad E[\epsilon] = 0 \quad \Rightarrow \quad E[\hat{\theta}] = \theta_0$$

- BLUE:

$$\hat{\theta} = (\Phi^T R^{-1} \Phi)^{-1} \Phi^T R^{-1} y$$

- MSE:

$$\text{MSE} = \text{bias}^2 + \text{variance}$$

- Regularised LS:

$$\hat{\theta} = (\Phi^T \Phi + \eta I)^{-1} \Phi^T y$$

- Convex set:

$$\gamma x_1 + (1 - \gamma)x_2 \in C$$

- PSD:

$$X \succeq 0 \Leftrightarrow z^T X z \geq 0 \quad \forall z$$

- MPC loop:

```
estimate state -> optimise horizon -> apply first input -> re-estimate -> repeat
```